

THÈSE DE MASTER II RECHERCHE

Développement d'un assistant gouvernemental intelligent par l'IA au Cameroun

Author :

NJILLA TCHAGADICK NICOL
EMMANUEL

Supervisors :

Pr Chantal Marie MVEH NÉE
ABIA
Pr Ghislain ABESSOLO ALO'O



Departement de Genie Informatique
ECOLE NATIONALE SUPERIEURE POLYTECHNIQUE DE YAOUNDE

Un mémoire soumis à l'Université de Yaoundé I conformément
aux exigences du diplôme de MASTER en Faculté d'Informa-
tique.

JUILLET 2026

TABLE OF CONTENTS

	Page
Table des figures	v
1 Introduction générale	1
1.1 Contexte national et motivation « IA endogène » : cas du Cameroun	2
1.2 Problème général	3
1.2.1 Objectif général	3
1.2.2 Objectifs spécifiques	3
1.2.3 Hypothèses de recherche	4
1.2.4 Contributions attendues	4
1.3 Mini-conclusion	5
2 Contexte : thématique et scientifique	7
2.1 Contexte thématique : administration, usagers, processus et documents	7
2.1.1 Bilinguisme institutionnel et implications techniques	7
2.1.2 Corpus documentaire et processus d'accès	10
2.2 Contexte scientifique : définitions clés	10
2.2.1 Grand modèle de langage (LLM)	10
2.2.2 Génération augmentée par la recherche (RAG)	10
2.2.3 Agent LLM outillé	11
2.2.4 Système cognitif et architecture cognitive	11
2.2.5 Mémoire des agents IA	11
2.2.6 Ontologie et graphe de connaissances	12
2.3 Contraintes et exigences	12
2.4 Spécification « IA endogène » : critères concrets	13
2.4.1 Critère E1 — Souveraineté des données et des dépendances	14
2.4.2 Critère E2 — Adaptation locale	14
2.4.3 Critère E3 — Gouvernance	14
2.4.4 Critère E4 — Maintenabilité et montée en compétence locale	15
2.4.5 Indice d'endogénéité composite	15
2.5 Mini-conclusion du chapitre	15

3	Problématique et état de l'art	17
3.1	Formulation détaillée de la problématique	17
3.2	Cadrage du domaine : assistant gouvernemental intelligent endogène	19
3.3	Problèmes abordés dans le domaine	19
3.3.1	Hallucinations et fiabilité	20
3.3.2	Obsolescence des connaissances	20
3.3.3	Bilinguisme et bijuridisme	20
3.3.4	Mémoire et personnalisation	21
3.3.5	Traçabilité et auditabilité	21
3.3.6	Gouvernance et gestion des risques	21
3.4	Ce que l'IA fait aujourd'hui pour résoudre ces problèmes	21
3.4.1	Génération augmentée par la recherche (RAG)	21
3.4.2	Agents LLM outillés et navigation web	22
3.4.3	Systèmes cognitifs et architectures cognitives	23
3.4.4	Représentation des connaissances : ontologies et graphes	24
3.4.5	Gouvernance, sûreté et responsabilité	25
3.5	Tableau comparatif des approches existantes	25
3.6	Synthèse critique : gap scientifique et positionnement	25
3.6.1	Identification des gaps	25
3.6.2	Positionnement de GOV-AI 2.0	26
3.6.3	Mini-conclusion	27
4	Méthodologie	31
4.1	Présentation de l'approche	31
4.1.1	Principes directeurs	32
4.1.2	Vue d'ensemble de l'architecture	33
4.1.3	Ce que GOV-AI 2.0 reprend de l'état de l'art	33
4.1.4	Ce que GOV-AI 2.0 apporte de nouveau	33
4.1.5	Justification des choix technologiques par analyse comparative	35
4.2	Données et constitution du corpus national	37
4.2.1	Sources documentaires	37
4.2.2	Pipeline d'ingestion	38
4.2.3	Versioning et horodatage	38
4.3	Pipeline de réalisation : de la requête à la réponse	38
4.3.1	Algorithme 1 — Orchestrateur cognitif (routage d'intention et sélection d'outils)	38
4.3.2	Algorithme 2 — Retrieval hybride avec fusion et reranking	39
4.3.3	Algorithme 3 — Agent web contrôlé	40
4.3.4	Algorithme 4 — Génération contrainte par citations	40

4.3.5	Algorithme 5 — Détection d’incertitude et vérification	40
4.3.6	Algorithme 6 — Politique de mémoire (write / read / prune / forget)	41
4.4	Protocole expérimental	42
4.4.1	Construction du jeu de questions (dataset)	42
4.4.2	Baselines et configurations (ablations incrémentales)	42
4.4.3	Scénarios d’évaluation	42
4.5	Métriques et critères d’évaluation	42
4.5.1	Métriques de génération	43
4.5.2	Métriques de l’agent web	43
4.5.3	Métriques d’équité bilingue	43
4.5.4	Métriques UX (optionnel)	43
4.5.5	Synthèse des métriques	44
4.6	Comparaison prévue avec les solutions existantes	44
4.7	Mini-conclusion du chapitre	44
	Bibliographie	53

TABLE DES FIGURES

INTRODUCTION GÉNÉRALE

La transformation numérique des administrations publiques constitue un enjeu majeur à l'échelle mondiale. Les Nations Unies relèvent, dans leur enquête sur l'administration électronique 2024, que la majorité des États membres ont engagé des stratégies de numérisation visant à améliorer l'accessibilité, la transparence et l'efficacité des services publics [55]. Dans ce mouvement, les progrès récents en intelligence artificielle — et plus particulièrement en grands modèles de langage (*Large Language Models*, LLM), en génération augmentée par la recherche (*Retrieval-Augmented Generation*, RAG) et en systèmes d'agents outillés — ouvrent des perspectives inédites pour la conception d'assistants conversationnels capables de comprendre des requêtes en langage naturel, de rechercher dans des corpus documentaires volumineux et de produire des réponses contextualisées avec citation des sources [28, 34, 61].

Plusieurs juridictions ont amorcé l'intégration de tels outils dans leurs services publics : l'Estonie explore l'initiative *KrattAI* comme point d'entrée unifié vers les services numériques ; la France a expérimenté des chatbots d'orientation sur *service-public.fr* ; des États américains utilisent des agents virtuels pour les FAQ citoyennes [39, 55]. Ces déploiements montrent des résultats encourageants en termes de réduction des délais et de satisfaction des usagers, mais révèlent aussi des limites structurelles : risque d'hallucination (génération d'informations plausibles mais fausses), absence d'ancrage sur des sources vérifiables, vulnérabilités aux attaques adversariales, et dépendance à des infrastructures et modèles propriétaires étrangers [21, 43].

Ce dernier point est critique pour les pays en développement. L'utilisation non maîtrisée de services d'IA hébergés à l'étranger soulève des questions de souveraineté des données, de dépendance technologique et de gouvernance. D'où l'émergence du concept d'*IA endogène* : une IA conçue, déployée et gouvernée localement, s'appuyant sur des données nationales, des compétences locales et une infrastructure sous contrôle de l'État. Ce concept constitue l'axe central non négociable du présent mémoire.

1.1 Contexte national et motivation « IA endogène » : cas du Cameroun

Le Cameroun, qualifié d’« Afrique en miniature » pour sa diversité culturelle et géographique, présente un paysage normatif d’une complexité singulière. Son système juridique est bijuridique — coexistence du droit civil d’inspiration romano-germanique et de la common law anglo-saxonne — et bilingue, le français et l’anglais constituant les deux langues officielles d’égale valeur (article 1(3) de la Constitution de 1996) [49]. À cette dualité s’ajoutent des sources normatives multiples : Constitution, codes nationaux, décrets présidentiels, actes uniformes de l’Organisation pour l’Harmonisation en Afrique du Droit des Affaires (OHADA), règlements communautaires de la CEMAC, circulaires ministérielles et droit coutumier. La résultante est un corpus documentaire vaste, distribué entre de nombreuses institutions, et dont la consultation exige souvent des déplacements physiques, des délais importants et une expertise préalable.

La plateforme mobile *nGomna*, déployée par le Centre National de Développement de l’Informatique (CENADI), a marqué une avancée notable en centralisant les bulletins de solde et les informations fiscales de plus de 400 000 agents publics [32]. Cependant, l’accès au corpus documentaire gouvernemental — textes juridiques, procédures administratives, formulaires, guides opérationnels — demeure largement fragmenté. Les délais de recherche peuvent atteindre plusieurs jours, voire plusieurs semaines, pour un document spécifique, avec un risque élevé d’erreurs d’interprétation et d’application de textes obsolètes [32].

Un travail antérieur (MFEGUE, 2025) a posé les fondations de GOV-AI : une IA conversationnelle gouvernementale intégrée à *nGomna*, reposant sur une architecture RAG agentique (OCR, segmentation, embeddings multilingues, indexation vectorielle, génération par LLM), orchestrée via LangChain en microservices et déployée sur infrastructure souveraine (mainframe IBM Z14, Mac Studio Server) [32]. Les résultats expérimentaux indiquent une réduction du temps moyen de recherche à moins de trois minutes et une précision observée supérieure à 85 %. Néanmoins, des lacunes scientifiques subsistent : taux d’hallucination de 15 %, absence de capacité de recherche web, mémoire limitée à la session, évaluation non formalisée, et sécurité LLM non traitée. Ces lacunes motivent le présent mémoire de master recherche.

La dimension endogène du projet se décline selon quatre critères concrets :

- **Souveraineté des données et des dépendances.** L’ensemble du corpus, des interactions utilisateurs et des logs sont hébergés sur infrastructure nationale. Les modèles utilisés (Llama, Qwen) sont *open source* et déployés localement.
- **Adaptation locale.** Le système gère le bilinguisme (FR/EN), le bijuridisme (droit civil / common law), et la terminologie administrative camerounaise.
- **Gouvernance.** Des mécanismes d’audit, de supervision humaine, de mise à jour du corpus et de responsabilité sont intégrés à l’architecture.

- **Maintenabilité et montée en compétence locale.** L'architecture modulaire et la documentation permettent aux équipes du CENADI de maintenir et faire évoluer le système sans dépendance extérieure.

1.2 Problème général

La problématique centrale du mémoire peut être formulée comme suit :

Comment concevoir et évaluer un assistant gouvernemental intelligent capable de répondre en langage naturel, de façon fiable, traçable et actualisée, à des questions administratives et juridiques, en contexte bilingue et bijuridique, tout en restant déployable dans un cadre de souveraineté des données et de gestion des risques ?

Cette problématique se décline en cinq questions de recherche :

- QR1 — Fiabilité et ancrage.** Quelles stratégies RAG multi-étapes minimisent le taux d'hallucination et maximisent la fidélité aux sources dans un domaine à risque [4, 28] ?
- QR2 — Agent web.** Comment intégrer un agent web capable de rechercher, naviguer, extraire et citer tout en restant sécurisé et contrôlable [34, 64] ?
- QR3 — Architecture cognitive.** Quelle structuration inspirée des systèmes cognitifs (perception, mémoire, planification, action, vérification) permet une robustesse supérieure et une explicabilité accrue [2, 12, 26] ?
- QR4 — Mémoire.** Quels mécanismes de mémoire (court terme, long terme, profils) assurent personnalisation et cohérence multi-tour sans compromettre la confidentialité [44, 47] ?
- QR5 — Évaluation.** Quels métriques et protocoles garantissent une évaluation reproductible couvrant retrieval, génération, agent web, mémoire, latence et satisfaction [33, 53, 64] ?

1.2.1 Objectif général

Proposer, formaliser et valider par protocole expérimental l'architecture d'un assistant gouvernemental de nouvelle génération (GOV-AI 2.0), conçu comme un système cognitif agentique endogène intégrant RAG interne, agent web, mémoire multi-niveaux, représentation structurée des connaissances et contrôle des risques, adapté au contexte camerounais.

1.2.2 Objectifs spécifiques

- O1. Réaliser un état de l'art structuré couvrant systèmes cognitifs, agents LLM, RAG, agents web, ontologies juridiques, mémoire des agents et gouvernance de l'IA en secteur public.
- O2. Définir une architecture cible (GOV-AI 2.0) fondée sur un cadre cognitif, intégrant orchestrateur cognitif, module RAG interne à citations obligatoires, agent web contrôlé, graphe de connaissances multi-profils et mémoire hiérarchique.

- O3. Formaliser les algorithmes critiques : routage d'intention, retrieval hybride avec reranking, génération contrainte par citations, détection d'incertitude, défense contre l'injection de prompts, et politiques de mémoire.
- O4. Concevoir un protocole d'expérimentation reproductible : jeu de questions bilingue annoté, baselines/ablations, métriques multi-niveaux, évaluation humaine et analyse d'erreurs.
- O5. Proposer un cadre de gouvernance opérationnel (NIST AI RMF, NIST AI 600-1, OWASP LLM Top 10) adapté au contexte camerounais.

1.2.3 Hypothèses de recherche

- H1 (Pipeline RAG multi-étapes).** Un pipeline RAG multi-étapes (reformulation, retrieval hybride, reranking, génération contrainte par citations) améliore la fidélité et réduit le taux d'hallucination par rapport à un RAG simple.
- H2 (Agent web contrôlé).** Un agent web limité à une liste blanche de domaines officiels, avec vérification et horodatage, réduit les réponses obsolètes ou erronées par rapport à un corpus interne statique.
- H3 (Mémoire hiérarchique).** Une mémoire hiérarchique (mémoire de travail + mémoire épisodique résumée + mémoire sémantique structurée par ontologie + profil) améliore la cohérence multi-tour et la personnalisation sans dégrader la conformité aux politiques de confidentialité.
- H4 (Architecture cognitive modulaire).** Une architecture structurée selon un cycle cognitif (percevoir — comprendre — délibérer — agir — vérifier — adapter) améliore la robustesse face aux requêtes complexes par rapport à une architecture monolithique.

1.2.4 Contributions attendues

- **Contribution théorique :** état de l'art structuré reliant systèmes cognitifs, RAG, agents web, ontologies, mémoire et gouvernance au contexte d'un assistant gouvernemental endogène.
- **Contribution architecturale :** spécification de GOV-AI 2.0, incluant orchestrateur cognitif, RAG à citations obligatoires, agent web contrôlé, graphe de connaissances multi-profils, mémoire hiérarchique, et mécanismes de vérification et sécurité.
- **Contribution méthodologique :** protocole d'évaluation reproductible (jeu de questions bilingue annoté, baselines/ablations, métriques multi-niveaux, évaluation humaine, analyse d'erreurs).
- **Contribution pratique :** cadre de gouvernance opérationnel adapté au contexte camerounais, articulant NIST AI RMF, NIST AI 600-1 et OWASP LLM Top 10.

Démarche globale et articulation du mémoire

La démarche adoptée est itérative et incrémentale. Elle part d'un prototype existant (GOV-AI 1.0), en identifie les limites par confrontation à l'état de l'art, puis propose une architecture de nouvelle génération (GOV-AI 2.0) dont chaque composant est justifié par des critères mesurables et évalué par un protocole reproductible.

Le mémoire est structuré en six parties (voir Figure 1.1) :

- **Section 2 — Contexte thématique et scientifique.** Spécificités camerounaises (bilinguisme, bijuridisme, acteurs, cas d'usage), définitions scientifiques clés, contraintes et critères d'IA endogène.
- **Section 3 — Problématique et état de l'art.** Formulation détaillée de la problématique, revue de littérature structurée (RAG, agents LLM, systèmes cognitifs, ontologies, mémoire, sécurité), tableau comparatif des approches existantes, synthèse critique et positionnement.
- **Section 4 — Méthodologie.** Présentation de l'approche, définition du modèle proposé (architecture GOV-AI 2.0), formalisation des algorithmes, constitution du corpus, pipeline de réalisation, protocole expérimental (scénarios, baselines, ablations), métriques et critères d'évaluation, plan de comparaison.
- **Section 5 — Résultats et discussion.** Résultats quantitatifs (retrieval, génération, groundedness, agent web, mémoire), analyse d'erreurs, discussion sur le niveau réel de souveraineté et les limites.
- **Section 6 — Conclusion générale et perspectives.** Bilan des contributions, limites, perspectives (extension du corpus, langues locales, industrialisation, gouvernance continue).

1.3 Mini-conclusion

Cette introduction a posé le cadre du mémoire en situant le projet GOV-AI 2.0 dans la double perspective de la transformation numérique mondiale et de la souveraineté numérique camerounaise. La problématique centrale, les cinq questions de recherche, les quatre hypothèses testables et les contributions attendues ont été formalisées. La section suivante détaillera le contexte thématique et scientifique dans lequel s'inscrit ce travail.

CONTEXTE : THÉMATIQUE ET SCIENTIFIQUE

Ce chapitre établit le double cadrage — thématique et scientifique — dans lequel s’inscrit le mémoire. La section 2.1 analyse les spécificités du contexte camerounais (bilinguisme, bijuridisme, acteurs, processus documentaires) et les traduit en contraintes de conception. La section 2.2 introduit les définitions scientifiques nécessaires à la compréhension du mémoire. La section 2.3 formalise les contraintes et exigences non fonctionnelles. La section 2.4 opérationnalise le concept d’IA endogène en critères concrets et mesurables.

2.1 Contexte thématique : administration, usagers, processus et documents

2.1.1 Bilinguisme institutionnel et implications techniques

Le Cameroun est constitutionnellement bilingue depuis la réunification de 1961, consacrée par l’article 1(3) de la Constitution de 1996 qui dispose que « la République du Cameroun adopte l’anglais et le français comme langues officielles d’égale valeur » [49]. Ce bilinguisme structure l’ensemble du fonctionnement administratif : les textes législatifs sont promulgués dans les deux langues, les procédures doivent être accessibles dans les deux langues, et les agents publics sont tenus de servir les citoyens dans leur langue de choix [1, 49].

En pratique, des asymétries subsistent. Certains textes ne sont disponibles que dans une seule langue, la terminologie juridique n’est pas toujours harmonisée entre les versions française et anglaise, et les régions anglophones (Nord-Ouest et Sud-Ouest) font face à des défis spécifiques d’accès à l’information [1]. Pour un assistant IA, le bilinguisme engendre quatre types de requêtes techniques distincts : (i) requête monolingue avec corpus concordant (cas simple) ; (ii) requête

monolingue mais corpus uniquement dans l'autre langue (exigeant un retrieval cross-lingue);
 (iii) requête avec alternance de codes (*code-switching* FR/EN, phénomène courant au Cameroun);
 (iv) requête nécessitant une correspondance terminologique entre concepts bijuridiques non symétriques (par exemple, « mise en demeure » vs. « formal notice »).

Pour quantifier la parité de performance entre les deux langues, nous définissons un indice de symétrie bilingue (ISB). Soient S_{FR} le score moyen (par exemple, l'exactitude) sur les questions en français et S_{EN} le score moyen sur les questions en anglais :

$$(2.1) \quad ISB = \frac{\min(S_{FR}, S_{EN})}{\max(S_{FR}, S_{EN})}$$

Un ISB de 1,0 indique une parité parfaite. Un seuil d'acceptabilité de $ISB \geq 0,85$ est proposé, signifiant que la performance dans la langue la moins bien servie ne doit pas descendre en dessous de 85 % de la performance dans la langue dominante.

Contrainte C1 (bilinguisme). Le système doit atteindre un $ISB \geq 0,85$ sur l'ensemble des métriques d'évaluation (retrieval, génération, satisfaction).

Bijuridisme : droit civil et common law

Le système juridique camerounais est le produit d'un héritage colonial double : le droit civil d'inspiration française s'applique dans les huit régions francophones, tandis que la *common law* d'inspiration anglaise prévaut dans les deux régions anglophones [37]. Cette dualité affecte la nature des sources du droit, les modes de raisonnement juridique et la terminologie. En droit civil, la source primaire est la loi codifiée, interprétée par la jurisprudence (raisonnement déductif). En *common law*, la jurisprudence (*case law*) constitue une source à part entière, avec un raisonnement inductif et analogique fondé sur les précédents [37].

À cette dualité s'ajoutent des sources transversales applicables uniformément : la Constitution, les actes uniformes OHADA (droit des affaires), les conventions internationales ratifiées, et les textes fédéraux antérieurs à 1996 [41]. Le droit coutumier, reconnu dans certains domaines (foncier, famille), ajoute un niveau de complexité supplémentaire.

Pour un assistant gouvernemental, le bijuridisme impose quatre règles de conception :

R1 (détection du système applicable). Si la requête contient des indices permettant d'identifier le système juridique applicable (mention d'une région, d'un type de juridiction, d'un concept propre), le système oriente sa recherche en conséquence.

R2 (signalement de divergence). Si la requête est ambiguë et que les réponses diffèrent selon le système, le système présente les deux positions avec un avertissement explicite.

R3 (corpus transversal prioritaire). Pour les matières couvertes par des textes uniformes (OHADA, Constitution), le système privilégie ces sources indépendamment du système régional.

R4 (escalade en cas d'incertitude). Si la divergence est significative et non résoluble automatiquement, le système recommande la consultation d'un professionnel.

Contrainte C2 (bijuridisme). Le système doit détecter correctement le système juridique applicable dans ≥ 90 % des requêtes testées, et signaler toute divergence non résolue.

Acteurs et profils utilisateurs

L'assistant GOV-AI 2.0 cible quatre profils principaux, chacun caractérisé par des besoins informationnels, un niveau d'expertise et des attentes de format distincts.

Le citoyen (P1) cherche à comprendre ses droits, connaître les étapes d'une démarche ou localiser le service compétent. Son expertise juridique est faible ; il attend des réponses vulgarisées, orientées action (« que dois-je faire ? »). L'agent public (P2) utilise le système comme outil d'aide à la décision : il recherche des textes réglementaires précis, des procédures internes, des circulaires. Il attend des réponses référencées et structurées. L'entreprise (P3) cherche des informations réglementaires liées à l'activité économique (création d'entreprise, fiscalité, marchés publics, actes OHADA). Le juriste (P4) — avocat, magistrat, notaire — utilise le système pour la recherche juridique approfondie et attend des réponses exhaustives avec références précises et registre technique.

Le Tableau 2.1 formalise l'adaptation du registre et du niveau d'explication selon les profils.

TABLE 2.1 – Matrice Profil $\times$ Dimension

Dimension	P1 (Citoyen)	P2 (Agent)	P3 (Entreprise)	P4 (Juriste)
Registre	Vulgarisé, pédagogique	Administratif, structuré	Professionnel, pratique	Technique, juridique
Citations	Optionnelles (en note)	Systématiques	Systématiques (textes + formulaires)	Exhaustives (articles, jurisprudence)
Niveau de détail	Synthétique, orienté action	Moyen, orienté procédure	Moyen, orienté conformité	Approfondi, orienté argumentation
Tolérance au jargon	Faible	Moyenne	Moyenne	Élevée
Suggestions proactives	Formulaires, guichets	Textes connexes, circulaires	Textes OHADA, formulaires	Jurisprudence, doctrine

Cette matrice sera encodée dans le système de prompting et dans l'ontologie multi-profils (Section 4), de sorte que l'orchestrateur cognitif puisse adapter automatiquement la génération.

Contrainte C5 (multi-profils). Le système doit adapter le registre et le niveau de détail au profil utilisateur, avec un taux de satisfaction différencié par profil mesuré via le questionnaire SUS [6].

2.1.2 Corpus documentaire et processus d'accès

Le corpus documentaire gouvernemental camerounais comprend plusieurs catégories de documents, organisées selon une hiérarchie normative (Constitution > lois organiques > lois ordinaires > ordonnances > décrets > arrêtés > circulaires). Ces documents existent sous des formats hétérogènes : textes numériques natifs (PDF, HTML), scans de documents physiques (nécessitant une extraction OCR), fichiers bureautiques, et documents manuscrits non numérisés. La qualité variable des scans — certains datant de plusieurs décennies — introduit du bruit dans le contenu textuel extrait, avec un impact en cascade sur les performances de retrieval [62].

Les processus d'accès actuels sont caractérisés par la dispersion (documents répartis entre ministères, délégations régionales, services déconcentrés), la latence (délais de plusieurs jours à plusieurs semaines pour un document spécifique), et le risque d'obsolescence (application de textes abrogés ou modifiés) [32]. L'assistant GOV-AI 2.0 vise à réduire ces trois problèmes par un accès unifié, rapide et actualisé au corpus, complété par une capacité de recherche web sur les sites institutionnels.

2.2 Contexte scientifique : définitions clés

Cette sous-section introduit les concepts scientifiques fondamentaux utilisés dans le mémoire. Chaque terme est défini formellement avant son premier usage substantiel.

2.2.1 Grand modèle de langage (LLM)

Un grand modèle de langage est un réseau neuronal de type Transformer [56] entraîné par prédiction autorégressive sur un corpus textuel massif. Formellement, il estime la probabilité jointe d'une séquence de tokens $x = (x_1, x_2, \dots, x_n)$ comme un produit de probabilités conditionnelles :

$$(2.2) \quad P(x) = \prod_{t=1}^n P(x_t \mid x_1, \dots, x_{t-1})$$

Les LLM modernes (GPT-4 [40], Claude [3], Llama [31]) sont affinés par *instruction tuning* et *reinforcement learning from human feedback* (RLHF) pour suivre des instructions et produire des réponses utiles et sûres [42]. Ils constituent le moteur de raisonnement linguistique de GOV-AI 2.0, mais présentent des limites structurelles — hallucinations, sur-confiance, obsolescence des connaissances — qui justifient le recours à des mécanismes d'ancrage et de vérification [21, 22].

2.2.2 Génération augmentée par la recherche (RAG)

Le paradigme RAG, introduit par Lewis *et al.* [28], combine recherche d'information et génération. Le système récupère des passages pertinents depuis une base documentaire puis

les fournit en contexte au LLM afin de produire une réponse ancrée sur des sources vérifiables. Formellement, pour une requête q , la réponse r est conditionnée par :

$$(2.3) \quad P(r | q) = \sum_d P(r | q, d) \cdot P(d | q)$$

où $P(d | q)$ est la pertinence du document d estimée par le retriever, et $P(r | q, d)$ la probabilité de la réponse conditionnée au document. Le RAG est le mécanisme central de réduction des hallucinations dans GOV-AI 2.0.

2.2.3 Agent LLM outillé

Un agent LLM est un système dans lequel un modèle de langage joue le rôle de contrôleur central, pilotant de manière itérative une boucle « raisonner — agir — observer » en interaction avec un environnement via un ensemble d'outils (recherche, navigation web, bases de données) [51, 61]. À la différence d'un pipeline RAG séquentiel, l'agent décide dynamiquement quelles actions entreprendre, dans quel ordre, en fonction des observations intermédiaires.

2.2.4 Système cognitif et architecture cognitive

Un système cognitif est un artefact logiciel capable de percevoir son environnement, de former et maintenir des représentations internes, de raisonner pour planifier des actions, d'exécuter ces actions et d'évaluer leurs conséquences afin d'adapter son comportement [57]. Une architecture cognitive fournit une organisation générale de ces capacités. Les architectures classiques — ACT-R [2], Soar [26], LIDA [12] — distinguent plusieurs types de mémoire (travail, déclarative, procédurale, épisodique) et des mécanismes de contrôle (résolution de conflit, impasses, attention). Dans GOV-AI 2.0, le cadre cognitif structure l'orchestration des composants (perception, mémoire, planification, action, vérification) et fournit un vocabulaire commun pour la traçabilité des décisions.

2.2.5 Mémoire des agents IA

La mémoire dans un agent LLM se décline en quatre niveaux [44, 63] : (i) mémoire de travail (fenêtre de contexte du LLM, volatile), (ii) mémoire épisodique (historique des interactions, persistante), (iii) mémoire sémantique (connaissances factuelles du domaine : corpus documentaire, graphe de connaissances), et (iv) mémoire de profil (rôle, préférences, consentements de l'utilisateur). La gestion de ces mémoires — écriture, lecture, consolidation, oubli — constitue un enjeu de performance (cohérence multi-tour, personnalisation) et de gouvernance (confidentialité, consentement).

2.2.6 Ontologie et graphe de connaissances

Une ontologie est une spécification explicite et formelle d'une conceptualisation partagée d'un domaine [16]. Elle définit des classes, des relations, des instances et des axiomes permettant le raisonnement automatisé. Un graphe de connaissances (*knowledge graph*, KG) est une structure de données orientée graphe où les nœuds représentent des entités et les arêtes des relations typées, souvent exprimées sous forme de triplets (sujet, prédicat, objet) [20]. Dans GOV-AI 2.0, l'ontologie modélise les institutions, les procédures, les textes normatifs, les profils utilisateurs et leurs relations, complétant le RAG par une couche structurée d'explicabilité et de personnalisation.

2.3 Contraintes et exigences

Les contraintes identifiées dans le contexte thématique (§2.1) et dans les référentiels de gestion des risques IA [35, 36, 43] sont formalisées ci-dessous. Elles délimitent l'espace de conception et serviront de critères d'évaluation tout au long du mémoire.

Contrainte C3 (traçabilité). 100 % des assertions factuelles dans les réponses doivent être associées à une citation vérifiable. Le taux de *Citation Precision* (proportion de citations renvoyant effectivement au contenu allégué) doit être ≥ 95 %. Cette exigence distingue fondamentalement un assistant gouvernemental d'un chatbot grand public et impose un fonctionnement en *citing-by-design* : aucune assertion factuelle n'est émise sans référence à une source identifiable [34, 35].

Contrainte C4 (risques IA). Le système doit intégrer des contrôles pour chaque catégorie de risque identifiée par le NIST AI 600-1 [36] : hallucinations (taux ≤ 5 %), injection de prompts (taux de succès = 0 %), fuite de données personnelles (aucune fuite détectée en *red teaming*). Le coût de l'erreur est asymétrique : une non-réponse (le système admet son ignorance) est préférable à une réponse fausse présentée avec assurance.

Contrainte C6 (latence). Le temps de réponse perçu doit respecter : latence $p50 \leq 5$ s et $p95 \leq 15$ s pour une réponse complète. Le streaming progressif (token par token) est requis pour masquer partiellement la latence de génération [38].

Contrainte C7 (coût d'exploitation). Le système étant destiné à un usage public financé sur budget de l'État, l'utilisation de modèles *open source* déployés localement est privilégiée pour des raisons de coût et de souveraineté. Le travail de MFEGUE [32] a démontré la faisabilité d'un déploiement sur infrastructure CENADI avec des modèles *open source* (Llama, Qwen3-Embedding).

Contrainte C8 (disponibilité). Un objectif de disponibilité de 99,5 % (environ 44 heures d'indisponibilité par an) est proposé, avec des mécanismes de résilience (redondance, reprise sur panne, dégradation gracieuse en cas de surcharge).

Contrainte C9 (souveraineté des données). Les données du corpus gouvernemental et les interactions des utilisateurs doivent rester sous le contrôle de l'État camerounais. Aucune donnée ne doit transiter par des serveurs situés hors du territoire national sans autorisation explicite. Cette contrainte élimine les solutions reposant exclusivement sur des API cloud étrangères et favorise un déploiement *on-premise* ou sur cloud souverain.

Contrainte C10 (journalisation et auditabilité). Toutes les interactions doivent être journalisées de manière sécurisée (chiffrée, horodatée, non modifiable) pour permettre des audits a posteriori. Les logs doivent inclure : la requête, les documents récupérés, les outils appelés, les scores de pertinence, la réponse générée, et le feedback utilisateur le cas échéant [35, 43].

Le Tableau 2.2 synthétise la traçabilité entre contraintes, composants architecturaux et métriques.

TABLE 2.2 – Traçabilité Contrainte → Composant → Métrique

Contr.	Description	Composant(s)	Métrique(s)	Seuil cible
C1	Bilinguisme FR/EN	Embedding, LLM, Évaluation	ISB (Éq. 2.1), Recall@k bilingue	ISB $\geq 0,85$
C2	Bijuridisme	Ontologie, Orchestrateur	Taux détection système juridique	$\geq 90 \%$
C3	Traçabilité	Génération, Vérification	Citation Precision	$\geq 95 \%$
C4	Risques IA	Vérification, Sécurité	Hallucination Rate, injection	Hall. $\leq 5 \%$, inj. = 0 %
C5	Multi-profils	Ontologie, Prompting	SUS par profil	SUS $\geq 70/100$
C6	Latence	Toute la chaîne	p50, p95	p50 ≤ 5 s, p95 ≤ 15 s
C7	Coût	Infrastructure, Modèles	Coût par requête	À déterminer
C8	Disponibilité	Infrastructure	Uptime	$\geq 99,5 \%$
C9	Souveraineté	Déploiement	Localisation données	100 % <i>on-premise</i>
C10	Auditabilité	Logs, Monitoring	Complétude des logs	100 % journalisées

2.4 Spécification « IA endogène » : critères concrets

Le concept d'IA endogène, introduit en Section 1.2, doit être opérationnalisé en critères vérifiables pour dépasser le registre déclaratif. Nous proposons quatre critères, chacun associé à des indicateurs mesurables. L'ensemble forme un indice d'endogénéité qui permet d'évaluer le degré de maîtrise locale du système.

2.4.1 Critère E1 — Souveraineté des données et des dépendances

Ce critère exige que (a) 100 % des données du corpus et des données utilisateurs résident sur infrastructure sous contrôle de l'État camerounais (C9), (b) aucun appel API vers un fournisseur étranger ne soit nécessaire pour le fonctionnement nominal du système (les modèles LLM et d'embedding sont déployés localement), et (c) les licences des composants logiciels permettent un usage souverain sans restriction (*open source* Apache 2.0 ou équivalent). Le prototype GOV-AI 1.0 satisfait déjà ce critère grâce au déploiement sur infrastructure CENADI (mainframe IBM Z14, Mac Studio Server) avec des composants *open source* (Tesseract, Milvus, Llama, LangChain) [32].

Indicateur E1. Pourcentage de composants critiques (LLM, embedding, base vectorielle, OCR) déployés localement sous licence ouverte. Cible : 100 %.

2.4.2 Critère E2 — Adaptation locale

Ce critère couvre (a) le bilinguisme FR/EN avec retrieval cross-lingue (C1), (b) la gestion du bijuridisme avec détection automatique du système applicable (C2), (c) l'utilisation d'une terminologie administrative camerounaise dans l'ontologie et les prompts, et (d) l'adaptation du registre aux quatre profils utilisateurs (C5). L'adaptation locale se distingue d'une simple traduction : elle implique une modélisation des spécificités juridiques, institutionnelles et linguistiques qui ne sont couvertes par aucune solution générique existante.

Indicateur E2. Score composite = ISB $\times$ taux de détection bijuridique $\times$ taux d'adaptation profil. Cible : $\geq 0,70$.

2.4.3 Critère E3 — Gouvernance

Ce critère exige (a) l'existence d'un comité de gouvernance IA au sein de l'institution opératrice, responsable de la validation des politiques de contenu, de la supervision des mises à jour et de l'arbitrage des incidents ; (b) la conformité aux cadres de gestion des risques (NIST AI RMF [35], NIST AI 600-1 [36]) et de sécurité (OWASP LLM Top 10 [43]) ; (c) des mécanismes de supervision humaine à trois niveaux (monitoring, validation pour sujets sensibles, intervention/*rollback*) ; (d) la journalisation complète et l'auditabilité de toutes les interactions (C10).

La gouvernance distingue une IA endogène d'une IA simplement « locale » : il ne suffit pas d'héberger le système sur le territoire national, il faut que les processus de contrôle, de mise à jour et de responsabilité soient exercés par des acteurs nationaux compétents [39, 54].

Indicateur E3. Score binaire (0/1) pour chaque sous-critère (comité, cadre de risques, supervision, journalisation). Cible : 4/4.

2.4.4 Critère E4 — Maintenabilité et montée en compétence locale

Ce critère exige (a) une architecture modulaire documentée, permettant le remplacement indépendant de chaque composant (LLM, embedding, base vectorielle, ontologie) sans refonte du système ; (b) la disponibilité d’une documentation technique en français et en anglais, à un niveau de détail suffisant pour qu’une équipe d’ingénieurs locale puisse maintenir, diagnostiquer et faire évoluer le système ; (c) un plan de formation des équipes du CENADI aux outils de monitoring, de gestion du corpus et d’administration de l’ontologie.

La maintenabilité est un critère souvent négligé dans les projets de recherche mais essentiel pour la pérennité d’un système public. Un assistant gouvernemental dont la maintenance dépend d’experts étrangers n’est endogène que de nom.

Indicateur E4. Couverture de la documentation technique (% des composants documentés) + nombre de personnes formées à la maintenance. Cible : documentation $\geq 90 \%$, ≥ 3 personnes formées.

2.4.5 Indice d’endogénéité composite

Les quatre critères peuvent être agrégés en un indice composite :

$$(2.4) \quad IE = \frac{E_1 + E_2 + E_3 + E_4}{4}$$

où chaque E_i est normalisé sur $[0, 1]$. Un $IE \geq 0,80$ est proposé comme seuil d’acceptabilité pour un système qualifié d’endogène. Cet indice n’a pas de prétention universelle ; il constitue un outil d’auto-évaluation adapté au contexte du projet.

2.5 Mini-conclusion du chapitre

Ce chapitre a établi que le contexte camerounais impose un ensemble de contraintes de conception qui distinguent fondamentalement GOV-AI 2.0 d’un assistant conversationnel généraliste. Le bilinguisme (C1) exige un pipeline entièrement multilingue avec un indice de symétrie mesurable. Le bijuridisme (C2) impose une modélisation ontologique des deux traditions juridiques avec des règles explicites de gestion des divergences. Les exigences de traçabilité (C3), de gestion des risques (C4) et de multi-profiles (C5) conditionnent la conception de l’orchestrateur cognitif, du module de vérification et du système de prompting. Les contraintes non fonctionnelles (C6–C10) délimitent l’espace des choix architecturaux et d’infrastructure.

Les définitions scientifiques (§2.2) fournissent le vocabulaire commun nécessaire à la suite du mémoire. L’opérationnalisation de l’IA endogène en quatre critères mesurables (E1–E4, §2.4) et un indice composite (IE) permet de dépasser le registre déclaratif et d’évaluer objectivement le degré de maîtrise locale du système.

L'ensemble de ces contraintes et critères sera systématiquement invoqué dans les sections suivantes, en particulier lors de la problématique et de l'état de l'art (Section 3), de la méthodologie (Section 4) et de l'évaluation des résultats (Section 5).

PROBLÉMATIQUE ET ÉTAT DE L'ART

Ce chapitre présente la formulation détaillée de la problématique, le cadrage scientifique du domaine, les principaux problèmes abordés dans la littérature, les solutions proposées par l'état de l'art, ainsi qu'une synthèse critique permettant d'identifier les gaps scientifiques auxquels répond le présent mémoire. La section 3.1 explicite la problématique et les questions de recherche. La section 3.2 cadre le domaine d'étude. La section 3.3 expose les problèmes majeurs identifiés dans la littérature. La section 3.4 examine les approches actuelles pour les résoudre. La section 3.5 en propose une comparaison structurée. Enfin, la section 3.6 formule les gaps scientifiques et positionne GOV-AI 2.0 par rapport à l'existant.

3.1 Formulation détaillée de la problématique

La modernisation numérique de l'administration publique camerounaise génère un besoin croissant d'accès rapide, fiable et unifié à l'information normative et procédurale. Les textes juridiques, règlements, circulaires, formulaires et guides de procédures demeurent dispersés entre de multiples institutions, dans des formats hétérogènes (PDF, scans, documents bureautiques), ce qui entraîne des délais de recherche pouvant atteindre plusieurs jours, des erreurs d'interprétation et une inégalité d'accès à l'information [32].

Un travail antérieur (MFEGUE, 2025) a proposé GOV-AI, une IA conversationnelle gouvernementale intégrée à l'écosystème mobile *nGomna*, reposant sur une architecture RAG agentique combinant OCR, segmentation sémantique, embeddings multilingues, indexation vectorielle et génération par LLM, orchestrée en microservices [32]. Les résultats expérimentaux rapportent une réduction du temps moyen de recherche à moins de trois minutes et une précision observée

supérieure à 85 % en français et en anglais. Cependant, ce prototype présente des limites structurelles identifiées dans notre analyse (cf. section 3.6) : un taux d'hallucination résiduel de 15 %, l'absence de mécanisme de vérification des sources, l'incapacité à traiter des requêtes hors corpus, l'absence de mémoire inter-sessions, et un protocole d'évaluation insuffisamment formalisé.

L'objectif du présent mémoire est de concevoir l'architecture d'un assistant gouvernemental de nouvelle génération (GOV-AI 2.0), comparable dans l'expérience utilisateur à une application de type ChatGPT, mais adapté au contexte camerounais : bilinguisme officiel (français/anglais), bijuridisme (droit civil et *common law*), souveraineté des données, et exigences de traçabilité propres au secteur public. La problématique centrale se formule ainsi :

Comment concevoir et évaluer un assistant gouvernemental intelligent capable de répondre en langage naturel, de façon fiable, traçable et actualisée, à des questions administratives et juridiques, en contexte bilingue et bijuridique, tout en restant déployable dans un cadre de souveraineté des données et de gestion des risques ?

Cette problématique se décline en cinq questions de recherche :

- QR1 — Fiabilité et ancrage.** Quelles stratégies RAG multi-étapes minimisent le taux d'hallucination et maximisent la fidélité aux sources dans un domaine à risque [4, 28] ?
- QR2 — Agent web.** Comment intégrer un agent web capable de rechercher, naviguer, extraire et citer des informations sur des sites institutionnels, tout en restant sécurisé et contrôlable [34, 64] ?
- QR3 — Architecture cognitive.** Quelle structuration inspirée des systèmes cognitifs permet une robustesse opérationnelle et une explicabilité accrue [2, 12, 26] ?
- QR4 — Mémoire.** Quels mécanismes de mémoire assurent personnalisation et cohérence multi-tour sans compromettre la confidentialité [44, 47] ?
- QR5 — Évaluation.** Quels métriques et protocoles garantissent une évaluation reproductible couvrant retrieval, génération, agent web, mémoire, latence et satisfaction [33, 53, 64] ?

Quatre hypothèses de recherche guident le travail :

- H1 (Pipeline RAG multi-étapes).** Un pipeline RAG multi-étapes (reformulation, retrieval hybride, reranking, génération contrainte par citations) améliore la fidélité et réduit l'hallucination par rapport à un RAG simple.
- H2 (Agent web contrôlé).** Un agent web limité à une liste blanche de domaines officiels, avec vérification et horodatage, réduit les réponses obsolètes ou erronées par rapport à un corpus interne statique.
- H3 (Mémoire hiérarchique).** Une mémoire hiérarchique (mémoire de travail, épisodique résumée, sémantique structurée par ontologie) améliore la cohérence multi-tour et la personnalisation sans dégrader la conformité aux politiques de confidentialité.

H4 (Architecture cognitive modulaire). Une architecture structurée selon un cycle cognitif (perception — mémoire — planification — action — vérification) améliore la robustesse face aux requêtes complexes par rapport à une architecture monolithique.

3.2 Cadrage du domaine : assistant gouvernemental intelligent endogène

Le domaine de ce travail se situe à l'intersection de plusieurs sous-domaines de l'informatique et de l'IA : le traitement automatique des langues (NLP), la recherche d'information (IR), la génération augmentée par la recherche (RAG), les systèmes d'agents LLM outillés, les architectures cognitives, la représentation des connaissances (ontologies et graphes), la mémoire des agents, et la gouvernance de l'IA en secteur public.

Le qualificatif *endogène* est central dans ce mémoire. Nous définissons une « IA endogène » comme un système d'intelligence artificielle conçu, déployé et gouverné de manière à maximiser la souveraineté nationale sur l'ensemble de la chaîne de valeur. Concrètement, quatre critères opérationnels caractérisent cette endogénéité :

- **Souveraineté des données.** Les données du corpus gouvernemental et les interactions des utilisateurs restent sous le contrôle de l'État camerounais, hébergées sur infrastructure nationale (CENADI), sans transit par des serveurs extérieurs au territoire [32].
- **Indépendance technologique contrôlée.** La pile technique repose sur des composants *open source* (Llama pour le LLM, Milvus pour l'indexation vectorielle, Tesseract pour l'OCR, LangChain/LangGraph pour l'orchestration), déployables localement sans dépendance à des API commerciales étrangères [32].
- **Adaptation locale.** Le système intègre nativement le bilinguisme FR/EN, le bijuridisme (droit civil / *common law*), la terminologie administrative camerounaise, et les profils spécifiques des usagers (citoyen, agent public, juriste, entreprise).
- **Gouvernance et maintenabilité locale.** Les mécanismes de mise à jour du corpus, de supervision humaine, d'audit et de *rollback* sont opérables par des équipes locales, sans expertise externe permanente.

Ce cadrage distingue GOV-AI 2.0 des assistants juridiques commerciaux (Lexis+ AI, CoCounsel, Harvey) qui reposent sur des corpus propriétaires et des API cloud étrangères, ainsi que des initiatives d'e-gouvernement d'autres pays (*KrattAI* en Estonie [48], chatbots de *service-public.fr* en France) qui n'affrontent pas la complexité bijuridique et bilingue du contexte camerounais.

3.3 Problèmes abordés dans le domaine

L'état de l'art identifie sept problèmes scientifiques et techniques que tout assistant gouvernemental intelligent doit résoudre. Nous les présentons ci-dessous avec leurs implications

spécifiques pour le contexte camerounais endogène.

3.3.1 Hallucinations et fiabilité

Les grands modèles de langage (LLM) produisent des contenus plausibles mais factuellement incorrects, phénomène qualifié d'hallucination [21]. Ji *et al.* [21] distinguent les hallucinations intrinsèques (contradiction avec les sources fournies) et extrinsèques (fabrication non vérifiable). Dans le domaine juridique, une hallucination peut prendre la forme d'une citation de loi inexistante ou d'une procédure inventée, avec des conséquences potentiellement graves pour les usagers. Les évaluations publiées montrent que même GPT-4 n'atteint qu'environ 60 % de réponses à la fois vraies et informatives sur TruthfulQA [29], et les taux d'hallucination sont généralement plus élevés sur des tâches juridiques spécialisées [9]. Ce problème justifie le recours au paradigme RAG [28] et aux mécanismes de vérification [4, 13].

3.3.2 Obsolescence des connaissances

Un LLM est un instantané statique de son corpus d'entraînement. Toute information postérieure à sa date de coupure est inaccessible, et le modèle peut produire des réponses obsolètes sans le signaler [25]. Dans le contexte camerounais, où les textes réglementaires sont régulièrement amendés, abrogés ou remplacés, cette obsolescence est un risque critique. Kasai *et al.* [25] montrent que la précision des LLM diminue significativement pour les questions portant sur des événements postérieurs au *cutoff*. Ce problème motive l'intégration d'un agent web capable de vérifier l'actualité des informations sur les sites institutionnels.

Sources non fiables et injection de prompts

Les systèmes RAG et les agents web sont exposés à l'injection indirecte de prompts : un contenu malveillant inséré dans un document récupéré ou une page web peut détourner le comportement du LLM [15]. L'OWASP classe ce risque comme LLM01, le plus critique pour les applications LLM [43]. Dans un contexte gouvernemental, le vecteur d'attaque est le corpus documentaire lui-même ou les pages web consultées par l'agent. Les contrôles incluent la séparation instructions/données, le filtrage des contenus récupérés, le *sandboxing* des outils et la validation des sorties [35, 43].

3.3.3 Bilinguisme et bijuridisme

Le Cameroun est constitutionnellement bilingue (FR/EN) et bijuridique (droit civil dans les régions francophones, *common law* dans les régions anglophones) [49]. Cette dualité impose que le système gère le retrieval cross-lingue (une requête en français retrouvant un document en anglais), la terminologie bijuridique (« mise en demeure » vs. « notice of default »), et le *code-switching* fréquent dans les communications administratives camerounaises. Les modèles

d'embeddings multilingues récents (Qwen3-Embedding, multilingual-e5) sont conçus pour le cross-lingue, mais leur performance varie selon les domaines [33], et le domaine juridique camerounais, avec sa terminologie spécifique, constitue un cas exigeant.

3.3.4 Mémoire et personnalisation

Les assistants de type ChatGPT maintiennent une mémoire conversationnelle qui améliore la cohérence multi-tour et la personnalisation. Dans un contexte gouvernemental, cette mémoire soulève des enjeux de protection des données : minimisation, durées de conservation, suppression à la demande, chiffrement, et séparation entre données personnelles et connaissances publiques [44, 47]. La loi camerounaise n° 2010/012 relative à la cybersécurité et la cybercriminalité impose des obligations de consentement, de finalité et de sécurité [49]. La conception de la mémoire doit donc articuler ce qui est mémorisé, pour combien de temps, comment l'utilisateur contrôle l'oubli, et comment la mémoire est auditée.

3.3.5 Traçabilité et auditabilité

Dans un service public, chaque réponse doit pouvoir être auditée a posteriori [35, 36]. Cela implique la citation des sources documentaires, l'horodatage, la journalisation du chemin de décision de l'agent (outils appelés, documents récupérés, scores), et la possibilité de reconstituer le processus ayant conduit à une réponse. Cette exigence de *citing-by-design* distingue fondamentalement un assistant gouvernemental d'un chatbot grand public.

3.3.6 Gouvernance et gestion des risques

L'introduction d'IA générative dans le secteur public exige des cadres de gouvernance. Le NIST AI RMF 1.0 [35] identifie quatre fonctions (*Govern, Map, Measure, Manage*), et le profil GenAI NIST AI 600-1 [36] détaille les risques propres aux LLM. Les principes de l'UNESCO sur l'éthique de l'IA [54] et les recommandations de l'OCDE [39] complètent ce cadre. Pour un déploiement endogène au Cameroun, ces référentiels doivent être adaptés aux contraintes locales (infrastructure, compétences, cadre juridique).

3.4 Ce que l'IA fait aujourd'hui pour résoudre ces problèmes

Cette section examine les solutions proposées par la littérature selon six axes correspondant aux composants de l'architecture cible.

3.4.1 Génération augmentée par la recherche (RAG)

Le paradigme RAG, formalisé par Lewis *et al.* [28], conditionne la génération d'un LLM sur des documents récupérés dynamiquement depuis une base de connaissances externe. Formellement,

pour une requête q , le système produit une réponse r selon :

$$(3.1) \quad P(r | q) = \sum_{d \in D_q} P(r | q, d) \cdot P(d | q)$$

où $P(d | q)$ est la probabilité de pertinence du document d (estimée par le retriever) et $P(r | q, d)$ la probabilité de la réponse conditionnée (estimée par le LLM). En pratique, la sommation est approximée sur les k documents les plus pertinents.

Le pipeline RAG comprend : ingestion (extraction, nettoyage, segmentation en *chunks*), représentation (embeddings multilingues), indexation (moteur vectoriel et/ou lexical), retrieval (recherche hybride sparse+dense), reranking (cross-encodeurs), et génération contrainte par citations. La recherche hybride combine BM25 (recherche lexicale, performante sur les identifiants formels comme les numéros d'articles de loi) et le *dense retrieval* (recherche sémantique, performante pour les reformulations paraphrastiques et le cross-lingue) [24, 50]. La fusion des résultats peut utiliser la Reciprocal Rank Fusion (RRF) [8] :

$$(3.2) \quad \text{RRF}(d) = \sum_{r \in R} \frac{1}{k_{\text{RRF}} + \text{rang}_r(d)}$$

Les systèmes RAG modernes s'enrichissent de mécanismes d'auto-vérification. Self-RAG [4] entraîne le modèle à émettre des tokens de réflexion indiquant si les documents récupérés sont pertinents et si la réponse est fidèle aux sources. RARR [13] propose un pipeline *post-hoc* qui vérifie chaque assertion et la corrige si nécessaire. Le cadre RAGAS [11] propose des métriques automatisées (*faithfulness*, *answer relevancy*, *context precision/recall*) pour évaluer les pipelines RAG. Les benchmarks BEIR [53] et MTEB [33] structurent l'évaluation des modèles d'embeddings et de retrieval.

Lien avec GOV-AI 2.0. Le pipeline RAG constitue le composant central de l'architecture cible. Le choix d'une recherche hybride (BM25 + dense) avec fusion RRF est motivé par la complémentarité lexicale/sémantique indispensable pour un corpus juridique bilingue. Le reranking par cross-encodeur multilingue et la génération contrainte par citations (*citing-by-design*) répondent aux exigences de traçabilité du secteur public.

3.4.2 Agents LLM outillés et navigation web

Un agent LLM est un système où un modèle de langage pilote itérativement une boucle « penser — agir — observer » en appelant des outils pour exécuter des actions [58]. ReAct [61] formalise cette synergie entre raisonnement et action. Toolformer [51] montre qu'un modèle peut apprendre quand et comment appeler des outils. WebGPT [34] illustre un cadre où un agent navigue sur le web pour répondre en citant ses références.

L'évaluation des agents web repose sur des benchmarks spécialisés. WebArena [64] propose un environnement réaliste de 812 tâches : les meilleurs agents (GPT-4 + vision) plafonnent

à environ 14 % de taux de succès, soulignant la difficulté de la navigation web autonome. Mind2Web [10] évalue la capacité de grounding sur plus de 2 000 tâches. Ces benchmarks, bien que majoritairement anglophones, fournissent des protocoles méthodologiques transférables.

Les paradigmes de planification incluent Plan-and-Solve [59] (plan explicite puis exécution séquentielle) et Reflexion [52] (auto-critique verbale après échec). Pour les requêtes complexes, une approche hybride ReAct + planification préalable est recommandée [58].

Lien avec GOV-AI 2.0. L'agent web de GOV-AI 2.0 opère dans un cadre contrôlé : liste blanche de domaines institutionnels (*.gov.cm, ohada.org, *Journal Officiel*), extraction et citation obligatoires, détection de contradictions avec le corpus interne, journalisation complète, et défenses contre l'injection indirecte de prompts.

3.4.3 Systèmes cognitifs et architectures cognitives

Les architectures cognitives visent à organiser les capacités d'un système intelligent (perception, mémoire, raisonnement, planification, action, apprentissage) en un cadre computationnel général [26]. Trois architectures de référence sont pertinentes.

ACT-R [2] distingue mémoire déclarative (faits sous forme de *chunks* avec activation contextuelle), mémoire procédurale (règles de production en compétition) et buffers jouant le rôle de mémoire de travail à capacité limitée. La pertinence pour GOV-AI réside dans : l'activation contextuelle (analogue de la recherche vectorielle), le routage d'intention (analogue des productions), et la capacité limitée des buffers (analogue de la fenêtre de contexte LLM).

Soar [26, 27] modélise la cognition comme une recherche dans un espace de problèmes, avec un mécanisme d'impasse récursif : lorsqu'aucune production ne s'applique, un sous-objectif est créé automatiquement. L'apport principal pour GOV-AI est la planification par décomposition de requêtes complexes. Les versions récentes de Soar intègrent mémoire sémantique, mémoire épisodique et apprentissage par renforcement [27].

LIDA [12] s'inspire de la théorie de l'espace de travail global (*Global Workspace Theory*) de Baars [5]. Son cycle cognitif (compréhension → attention → sélection d'action) et son mécanisme de *broadcast* attentionnel sont pertinents pour la coordination multi-agents dans GOV-AI : l'orchestrateur cognitif joue le rôle de « cœur attentionnel » décidant quel résultat intermédiaire est diffusé aux sous-agents.

Un LLM seul ne constitue pas un système cognitif : il ne dispose ni de mémoire persistante structurée, ni de capacité de planification autonome, ni de métacognition fiable [23, 60]. L'approche adoptée est donc de traiter le LLM comme un composant — puissant mais incomplet — d'un système cognitif plus large, entouré de modules spécialisés (mémoire, outils, vérification).

Lien avec GOV-AI 2.0. L'architecture cible transpose le cycle cognitif en six phases : percevoir (normalisation, détection de langue), comprendre (extraction d'intention, enrichissement par

profil), délibérer (routage d'intention, planification), agir (sous-agents RAG, web, ontologie), vérifier (*groundedness check*, détection d'incertitude), adapter (mise à jour mémoire).

3.4.4 Représentation des connaissances : ontologies et graphes

Les ontologies fournissent une structuration explicite des concepts, relations et règles d'un domaine, permettant des requêtes et raisonnements formels [16]. Dans le domaine juridique, LKIF Core [19] modélise normes, actions, agents et rôles. LegalRuleML [45] permet de formaliser des règles juridiques avec métadonnées temporelles et juridictionnelles. Les graphes de connaissances (KG) facilitent la traçabilité (liens entre textes, articles, procédures) et le filtrage contextuel (par juridiction, langue, profil) [46].

L'hybridation KG + RAG est une direction active de la recherche. Pan *et al.* [46] montrent que la combinaison de recherche vectorielle sur texte non structuré et d'interrogation de graphes structurés améliore l'exactitude sur les benchmarks de question-réponse. Trois stratégies d'hybridation sont documentées : enrichissement de requête par le KG (résolution d'acronymes, ajout de termes liés), recherche parallèle et fusion des résultats (texte + graphe), et vectorisation des triplets du KG [46].

Lien avec GOV-AI 2.0. Une ontologie multi-profil camerounaise modélise les institutions, procédures, textes normatifs, concepts juridiques et profils utilisateurs, avec gestion du bijuridisme à trois niveaux (concepts communs, concepts spécifiques à une tradition, concepts sans équivalent). Le choix technologique recommandé est Neo4j + couche OWL (plugin n10s), combinant performances de traversée et rigueur formelle.

Mémoire des agents LLM

La mémoire dans les agents LLM se décline en quatre niveaux [63] : mémoire de travail (fenêtre de contexte, volatile), mémoire épisodique (historique des interactions, persistante), mémoire sémantique (connaissances stables du domaine), et mémoire de profil (rôle, préférences, consentements). MemGPT [44] propose une gestion inspirée de la mémoire virtuelle (*paging*) pour dépasser la limite de contexte. Les *Generative Agents* [47] montrent l'intérêt d'un scoring composite combinant récence, importance et pertinence pour la sélection mémorielle :

$$(3.3) \quad \text{score}(m_i, q, t) = \alpha \cdot \text{récence}(m_i, t) + \beta \cdot \text{importance}(m_i) + \gamma \cdot \text{pertinence}(m_i, q)$$

La fenêtre de contexte, bien que croissante, reste soumise au phénomène « lost in the middle » [30] et à un coût computationnel croissant. Les stratégies d'atténuation incluent le résumé incrémental, l'indexation vectorielle avec retrieval sélectif, et l'oubli contrôlé (*decay* temporel, consolidation, purge à la demande).

Lien avec GOV-AI 2.0. La mémoire est soumise à des contraintes de confidentialité spécifiques au secteur public : minimisation des données, séparation stricte données personnelles / connaissances publiques, chiffrement AES-256 au repos, cloisonnement par utilisateur, consentement explicite, et journalisation des accès pour audit.

3.4.5 Gouvernance, sûreté et responsabilité

Le NIST AI RMF 1.0 [35] structure la gestion des risques IA en quatre fonctions : *Govern* (structures de gouvernance), *Map* (identification des risques), *Measure* (métriques et évaluation), *Manage* (contrôles et mitigation). Le profil GenAI NIST AI 600-1 [36] détaille douze catégories de risques propres aux LLM, dont les plus critiques pour un assistant gouvernemental sont : GAI-5 (hallucinations), GAI-3 (données personnelles), GAI-6 (sécurité de l'information / prompt injection), et GAI-12 (dépendance aux composants tiers).

L'OWASP LLM Top 10 [43] fournit une taxonomie des vulnérabilités : LLM01 (prompt injection), LLM02 (*insecure output handling*), LLM08 (*excessive agency*). Les principes de l'UNESCO [54] et de l'OCDE [39] insistent sur la proportionnalité, l'équité, la transparence et la redevabilité.

Lien avec GOV-AI 2.0. Le cadre de gouvernance de GOV-AI 2.0 applique systématiquement le NIST AI RMF et l'OWASP LLM Top 10, avec des contrôles adaptés au contexte camerounais : modèles *open source* déployés localement (souveraineté, GAI-12), génération contrainte par citations (GAI-5), filtrage des entrées/sorties et *sandboxing* (GAI-6), mémoire minimisée avec chiffrement (GAI-3), et supervision humaine avec mécanisme d'escalade.

3.5 Tableau comparatif des approches existantes

Le Tableau 3.1 compare les approches et systèmes existants selon huit critères déterminants pour un assistant gouvernemental endogène camerounais. Les critères ont été sélectionnés à partir des contraintes identifiées au chapitre 2 (C1–C10) et des problèmes de la section 3.3.

Le Tableau 3.2 présente les forces et faiblesses des principales approches dans le contexte endogène camerounais.

3.6 Synthèse critique : gap scientifique et positionnement

3.6.1 Identification des gaps

L'analyse croisée de l'état de l'art et du prototype existant permet d'identifier cinq gaps scientifiques de criticité haute, récapitulés dans le Tableau 3.3.

Gap G1 — Architecture cognitive. Le prototype GOV-AI 1.0 décrit un cycle de raisonnement (perception → délibération → planification → exécution → évaluation → adaptation → synthèse)

mais ne le fonde pas sur les architectures cognitives classiques et ne dispose pas de mécanisme de métacognition. Or, dans un domaine à risque, la capacité du système à évaluer la fiabilité de ses propres réponses avant de les transmettre est un facteur critique de confiance. Les travaux sur Self-RAG [4], Reflexion [52] et CRITIC [14] montrent que l'auto-vérification améliore significativement la fidélité des réponses.

Gap G2 — Agent web. GOV-AI 1.0 est strictement confiné au corpus interne. Il ne peut ni répondre aux questions hors corpus, ni vérifier l'actualité des informations, ni compléter le corpus sur des sujets non couverts. L'état de l'art montre que les agents web (WebGPT [34], ReAct [61]) offrent un potentiel significatif pour compléter un RAG interne, sous réserve de contrôles stricts (liste blanche, *citing-by-design*, détection de contradictions, *sandboxing*).

Gap G3 — Mémoire. GOV-AI 1.0 ne dispose que d'une mémoire de session. L'absence de mémoire épisodique et de profil dégrade l'expérience utilisateur (perte de contexte, absence de personnalisation) et limite l'utilité pour les interactions complexes multi-tours. La littérature montre que la mémoire multi-niveaux est un différenciateur clé entre un outil de recherche et un assistant de type ChatGPT [44, 47, 63].

Gap G4 — Évaluation. Le taux de précision de 85 % rapporté par MFEGUE [32] n'est pas accompagné d'un protocole formalisé : pas de jeu de questions annoté, pas de métriques IR formelles, pas de mesure de *groundedness* ou d'hallucination, pas d'accord inter-annotateurs. Les cadres BEIR [53], MTEB [33], RAGAS [11], TruthfulQA [29] et LegalBench [17] fournissent des méthodologies éprouvées qui ne sont pas mobilisées.

Gap G5 — Sécurité. Le prototype traite la souveraineté au niveau infrastructure mais ne formalise pas les risques spécifiques aux systèmes GenAI. Le NIST AI RMF [35], le NIST AI 600-1 [36] et l'OWASP LLM Top 10 [43] ne sont pas mentionnés. Aucun test de robustesse adversariale n'est rapporté.

3.6.2 Positionnement de GOV-AI 2.0

Le présent mémoire vise à combler les cinq gaps identifiés par la proposition d'une architecture de nouvelle génération (GOV-AI 2.0) qui :

- **Formalise un cadre cognitif (G1)** : orchestrateur cognitif structuré en cycle perception — mémoire — planification — action — vérification, avec mappage explicite vers les composants techniques, module de détection d'incertitude, et politique de refus/escalade.
- **Intègre un agent web contrôlé (G2)** : limité à une liste blanche de domaines institutionnels, avec citation obligatoire, détection de contradictions, *sandboxing* et journalisation.

- **Implémente une mémoire hiérarchique (G3)** : mémoire de travail (résumé dynamique de session), mémoire épisodique (logs résumés et compressés), mémoire sémantique (corpus + ontologie), mémoire de profil (rôle, préférences, consentements), avec politiques de *write/read/prune/forget* conformes aux principes de minimisation.
- **Définit un protocole d'évaluation reproductible (G4)** : jeu de questions bilingue annoté, *baselines* et ablations incrémentales (B0–B5), métriques multi-niveaux (retrieval, génération, agent web, mémoire, latence, UX), évaluation humaine avec accord inter-annotateurs.
- **Propose un cadre de sécurité et gouvernance (G5)** : application systématique du NIST AI RMF, du NIST AI 600-1 et de l'OWASP LLM Top 10, avec contrôles adaptés au contexte camerounais.

L'ensemble de ces contributions s'inscrit dans la logique d'IA endogène : chaque composant est conçu pour être déployable sur infrastructure souveraine, opérable par des équipes locales, et adapté aux spécificités bilingues et bijuridiques du Cameroun. La Figure 3.1 synthétise le positionnement de GOV-AI 2.0 par rapport à l'existant et aux gaps identifiés.

Description de la Figure 3.1 — Positionnement de GOV-AI 2.0 par rapport aux gaps identifiés. Diagramme concentrique. Au centre : GOV-AI 1.0 (RAG agentique + microservices + bilinguisme). Cinq couches concentriques ajoutées par GOV-AI 2.0, chacune associée à un gap : (G1) Architecture cognitive et métacognition, (G2) Agent web contrôlé, (G3) Mémoire hiérarchique, (G4) Protocole d'évaluation, (G5) Sécurité et gouvernance. Une enveloppe extérieure englobante porte le label « IA Endogène : souveraineté, adaptation locale, gouvernance, maintenabilité ». Des flèches bidirectionnelles entre les couches illustrent les interactions (par ex. G1↔G2 : l'orchestrateur cognitif pilote l'agent web ; G3↔G5 : la mémoire est soumise aux politiques de sécurité).

3.6.3 Mini-conclusion

L'état de l'art montre que les briques technologiques nécessaires (RAG, agents LLM, architectures cognitives, ontologies, mémoire, cadres de gouvernance) sont disponibles et en maturation rapide, mais qu'aucune solution existante ne les intègre dans un cadre unifié adapté au contexte camerounais bilingue et bijuridique, avec les exigences de souveraineté et de traçabilité propres au secteur public. Les cinq gaps identifiés structurent directement la méthodologie (chapitre 4) et l'architecture cible qui y sera proposée.

TABLE 3.1 – Comparaison des approches existantes pour un assistant gouvernemental intelligent

Critère	RAG simple	RAG + reranking + citations	Agent LLM outillé	Assistants juridiques commerciaux	GOV-AI 1.0	KrattA
Ancrage sur sources	Oui (documents récupérés)	Oui + vérification automatique	Oui (web + corpus)	Oui (corpus propriétaire)	Oui (corpus interne)	Partiel (FAQ)
Réduction hallucinations	Modérée	Élevée (auto-vérification)	Variable (dépend du contrôle)	Élevée (corpus contrôlé)	Modérée (15 % hall.)	Faible (règles)
Actualisation (web)	Non	Non	Oui	Partielle (mise à jour éditeur)	Non	Non
Mémoire multi-niveaux	Non	Non	Partielle (<i>ReAct</i> stateful)	Oui (sessions)	Session seule	Non
Bilinguisme FR/EN	Dépend embedding	Dépend embedding	Dépend LLM	Non (EN dominant)	Oui (Qwen3-Emb.)	Non (enien)
Bijuridisme	Non	Non	Non	Non	Non	Non
Souveraineté données	Possible (<i>open source</i>)	Possible	Possible	Non (cloud privé)	Oui (CE-NADI)	Partiell
Évaluation formelle	RAGAS, BEIR	RAGAS + auto-évaluation	WebArena, Mind2Web	Non publique	Non formalisée	Non blique

TABLE 3.2 – Forces et faiblesses des approches en contexte endogène camerounais

Approche	Forces	Faiblesses en contexte endogène
RAG simple [28]	Réduction des hallucinations, traçabilité des sources	Pas de mise à jour web, pas de vérification, pas de personnalisation
RAG avancé (Self-RAG [4], RARR [13])	Auto-vérification, fidélité accrue	Requiert <i>fine-tuning</i> spécifique (Self-RAG), latence supplémentaire (RARR)
Agent web (WebGPT [34], ReAct [61])	Accès à l'information à jour, complémentarité avec corpus interne	Taux de succès encore faibles (< 15 % sur WebArena [64]), risques de sécurité (injection indirecte)
Architectures cognitives (ACT-R [2], Soar [26])	Structuration, décomposition de requêtes complexes, métacognition	Non conçues pour les LLM, transposition analogique
Ontologies juridiques (LKIF [19], Legal-RuleML [45])	Raisonnement formel, explicabilité, gestion du bijuridisme	Coût de peuplement, absence d'ontologie pour le droit camerounais
Mémoire des agents (MemGPT [44], Generative Agents [47])	Cohérence multi-tour, personnalisation	Enjeux de confidentialité en secteur public, complexité d'implémentation
GOV-AI 1.0 [32]	Déployé, souverain, bilingue, microservices	Pas de web, pas de mémoire long terme, évaluation non formalisée, pas de métacognition

TABLE 3.3 – Gaps scientifiques identifiés et traçabilité vers les questions de recherche

Gap	Description	QR associée	Hypothèse	Criticité
G1 — Cognitif	Absence d'architecture cognitive formelle avec métacognition (détection d'incertitude, refus, escalade)	QR3	H4	Haute
G2 — Agent web	Absence de capacité de recherche/navigation web contrôlée pour actualisation et vérification	QR2	H2	Haute
G3 — Mémoire	Absence de mémoire multi-niveaux (épisodique, profil) avec politiques de confidentialité	QR4	H3	Haute
G4 — Évaluation	Absence de protocole d'évaluation reproductible (métriques formelles, jeu de questions annoté, ablations)	QR5	H1–H4	Haute
G5 — Sécurité	Absence de cadre de sécurité formalisé pour les risques GenAI (OWASP, NIST AI 600-1)	QR1, QR2	H1	Haute

MÉTHODOLOGIE

Ce chapitre présente la méthodologie adoptée pour concevoir, formaliser et évaluer l'architecture GOV-AI 2.0. Il explicite l'approche générale, définit le modèle proposé, décrit les choix technologiques retenus, formalise les algorithmes critiques, précise la constitution du corpus national, et établit le protocole expérimental ainsi que les métriques d'évaluation. L'objectif est de fournir un cadre méthodologique rigoureux, reproductible et cohérent avec les exigences d'une IA endogène appliquée au contexte camerounais.

4.1 Présentation de l'approche

La démarche méthodologique adoptée dans ce mémoire s'articule en trois phases complémentaires, alignées sur les cinq gaps scientifiques identifiés au chapitre 3 (G1–G5) et sur les exigences de l'IA endogène.

Phase 1 — Conception architecturale (G1, G2, G3). À partir de l'état de l'art sur les systèmes cognitifs [2, 12, 26], les agents LLM [34, 61], les systèmes RAG [4, 28], la mémoire [44, 47] et les ontologies [19], nous définissons l'architecture cible GOV-AI 2.0 comme un système cognitif agentique intégrant cinq composants : un orchestrateur cognitif, un module RAG interne à citations obligatoires, un agent web contrôlé, un graphe de connaissances multi-profils, et une mémoire hiérarchique. Chaque composant est spécifié par ses interfaces, ses algorithmes critiques et ses politiques de contrôle.

Phase 2 — Protocole expérimental (G4). Nous concevons un protocole d'évaluation reproductible fondé sur : un jeu de questions bilingue annoté par des experts, six configurations

incrémentales (baselines et ablations) permettant de mesurer l'apport de chaque composant, des métriques multi-niveaux couvrant le retrieval, la génération, l'agent web, la mémoire, la latence et la satisfaction, et une évaluation humaine avec accord inter-annotateurs.

Phase 3 — Cadre de sécurité et gouvernance (G5). Nous appliquons systématiquement le NIST AI RMF 1.0 [35], le profil GenAI NIST AI 600-1 [36] et l'OWASP LLM Top 10 [43] pour identifier les menaces, définir les contrôles techniques et organisationnels, et spécifier les mécanismes de journalisation, d'auditabilité et de supervision humaine.

Cette démarche est de nature *design science* [18] : elle produit un artefact (l'architecture GOV-AI 2.0) et évalue sa validité par un protocole expérimental. Le périmètre se limite à la conception et à la spécification de l'architecture, avec un protocole d'évaluation exécutable sur prototype ; le déploiement en production à grande échelle est hors périmètre mais constitue une perspective.

Définition du modèle proposé : architecture GOV-AI 2.0

4.1.1 Principes directeurs

L'architecture GOV-AI 2.0 repose sur cinq principes issus de l'état de l'art et adaptés au contexte camerounais.

Principe 1 — Structuration cognitive. Transposition du cycle cognitif (percevoir → comprendre → délibérer → agir → vérifier → adapter) en composants techniques explicites, inspiré d'ACT-R [2], Soar [26] et LIDA [12]. Ce principe répond au gap G1 et à la question QR3.

Principe 2 — Ancrage systématique sur sources (*citing-by-design*). Toute assertion factuelle de la réponse doit être supportée par une source identifiable, conformément aux exigences de traçabilité du secteur public [35]. Ce principe répond au gap G4 et à la question QR1.

Principe 3 — Contrôle et auditabilité. Chaque action de l'agent (appel d'outil, document récupéré, page web consultée, décision de l'orchestrateur) est journalisée avec horodatage, permettant une reconstitution complète du chemin de décision. Ce principe répond au gap G5.

Principe 4 — Endogénéité. Tous les composants sont déployables sur infrastructure souveraine (CENADI) à l'aide de logiciels *open source*. Aucune donnée ne transite hors du territoire national. Les modèles (LLM, embeddings, reranker) sont *open source* et adaptables localement. Ce principe est transversal aux cinq gaps.

Principe 5 — Modularité et évolutivité. L'architecture microservices héritée de GOV-AI 1.0 [32] est maintenue et étendue. Chaque sous-agent est remplaçable indépendamment, facilitant les mises à jour et la montée en compétence locale.

4.1.2 Vue d'ensemble de l'architecture

L'architecture se décompose en sept couches fonctionnelles, dont le Tableau 4.1 détaille les correspondances avec le cycle cognitif et les composants techniques.

Description de la Figure 4.1 — Architecture fonctionnelle de GOV-AI 2.0. Schéma en couches. En haut : [Interface Mobile/Web (*nGomna*)] → [API Gateway + Auth MFA]. Au centre : [Orchestrateur cognitif] relié par des flèches bidirectionnelles à quatre sous-agents disposés en étoile : [Agent RAG interne] → [Vector DB (Milvus) + Doc Store + Index BM25], [Agent Graphe/Ontologie] → [Neo4j + couche OWL], [Agent Web] → [Cache horodaté + Liste blanche domaines], [Agent Mémoire] → [Memory Store chiffré]. En dessous de l'orchestrateur : [Module de Vérification] (groundedness, incertitude, citations, contradictions). En sortie : [Réponse : texte + citations + avertissements + suggestions]. À droite, en transversal : [Module Sécurité & Journalisation] relié à tous les composants. Chaque sous-agent porte un label avec sa phase cognitive. Enveloppe globale : « Déploiement souverain — Infrastructure CENADI ».

4.1.3 Ce que GOV-AI 2.0 reprend de l'état de l'art

Le Tableau 4.2 récapitule les éléments repris de la littérature et du prototype existant.

4.1.4 Ce que GOV-AI 2.0 apporte de nouveau

Les contributions originales de GOV-AI 2.0, au-delà de l'intégration des composants existants, se concentrent sur cinq apports :

- **Orchestrateur cognitif unifié.** Aucun système existant ne combine, dans un cadre cognitif explicite, RAG interne, agent web contrôlé, graphe de connaissances bijuridique et mémoire hiérarchique, avec un module de métacognition (détection d'incertitude, refus, escalade). Le mappage formel entre phases cognitives et composants techniques (Tableau 4.1) constitue un outil de conception original.
- **Gestion native du bijuridisme.** La modélisation ontologique à trois niveaux (concepts communs, concepts spécifiques à une tradition, concepts sans équivalent) est une contribution nouvelle, aucune ontologie juridique existante ne traitant la coexistence droit civil / *common law* au sein d'un même État.
- **Agent web gouvernemental sécurisé.** La combinaison liste blanche de domaines institutionnels + *citing-by-design* obligatoire + détection de contradictions avec le corpus interne + défenses contre l'injection indirecte constitue un cadre spécifique au secteur public non décrit dans la littérature.
- **Politiques de mémoire conformes au secteur public.** L'articulation consentement + minimisation + cloisonnement par utilisateur + oubli contrôlé + journalisation des accès, formalisée dans des algorithmes explicites, répond aux exigences de protection des données camerounaises.

TABLE 4.1 – Mappage cycle cognitif → composants techniques GOV-AI 2.0

Phase cognitive	Fonction	Composant technique	Référence théorique
Percevoir	Réception et normalisation des entrées	Module NLU : détection de langue (Langdetect), extraction d'entités, classification d'intention; ASR (Whisper); OCR (Tesseract)	ACT-R (module visuel), LIDA (codelets de perception)
Comprendre	Enrichissement contextuel	Fenêtre de contexte LLM + résumé dynamique de session + enrichissement par profil (ontologie)	ACT-R (buffers + activation par diffusion)
Délibérer	Routage et planification	Orchestracteur cognitif : routage d'intention, sélection d'outils, planification multi-étapes	Soar (impasses → sous-objectifs), LIDA (broadcast)
Agir	Exécution des actions	Sous-agents outillés : Agent RAG (retrieval hybride + reranking + génération), Agent Web (recherche + navigation + extraction), Agent Graphe (requêtes SPARQL/Cypher), Agent Mémoire (read/write/prune)	Soar (opérateurs), ReAct [61]
Vérifier	Métacognition	Module de vérification : groundedness check, détection d'incertitude, contrôle de citations, détection de contradictions	Self-RAG [4], CRITIC [14]
Adapter	Mise à jour des mémoires	Mise à jour mémoire épisodique (résumé), mémoire de profil (préférences), logs d'audit	ACT-R (renforcement d'utilité), Soar (chunking)
— (transversal)	Sécurité	Filtrage entrées/sorties, sandboxing outils, journalisation, supervision humaine	NIST AI 600-1 [36], OWASP [43]

- **Protocole d'évaluation bilingue et bijuridique.** La construction d'un jeu de questions bilingue annoté par des experts camerounais, avec des métriques adaptées (indice de symétrie bilingue, taux de détection du système juridique applicable) et des ablations incrémentales, n'existe dans aucun travail antérieur.

4.1.5 Justification des choix technologiques par analyse comparative

Chaque composant technique de l'architecture GOV-AI 2.0 résulte d'une analyse comparative multi-critères, évaluée selon les contraintes identifiées au chapitre 2 : bilinguisme (C1), bijuridisme (C2), traçabilité (C3), gestion des risques (C4), multi-profils (C5), latence (C6), coût (C7), disponibilité (C8), souveraineté (C9) et auditabilité (C10). Cette section présente, pour chaque brique technologique majeure, les alternatives considérées, les critères de sélection et la justification du choix retenu.

4.1.5.1 Modèle de langage (LLM) pour la génération

Le choix du LLM est structurant car il conditionne la qualité de la génération, la latence, le coût et la conformité à la contrainte de souveraineté (C9). Trois catégories de modèles ont été évaluées : les modèles propriétaires accessibles par API, les modèles *open source* de grande taille, et les modèles *open source* de taille intermédiaire.

Choix retenu : Llama 3.1 70B (avec Qwen 2.5 72B comme alternative). Ce choix est motivé par trois arguments. Premièrement, la contrainte de souveraineté (C9) élimine les modèles propriétaires accessibles uniquement par API cloud, car les données gouvernementales camerounaises ne doivent pas transiter hors du territoire national. Deuxièmement, les performances de Llama 3.1 70B et Qwen 2.5 72B sur les benchmarks multilingues (incluant le français et l'anglais) sont suffisantes pour un usage RAG, où le modèle génère à partir de sources fournies plutôt que de sa connaissance paramétrique. Troisièmement, la compatibilité avec les techniques de quantification (QLoRA en 4 bits) permet un déploiement sur l'infrastructure existante du CENADI (Mac Studio Server, GPU A100). Le choix entre Llama et Qwen sera arbitré expérimentalement lors de la phase d'évaluation (chapitre 5), en mesurant la qualité de génération bilingue sur le jeu de questions camerounais. Mistral Large constitue une troisième option viable, notamment pour ses performances en français, et sera inclus dans les tests comparatifs.

Lien avec GOV-AI 1.0. Le prototype de MFEGUE [32] utilisait Llama 4 via Ollama. GOV-AI 2.0 maintient cette approche tout en élargissant l'évaluation à d'autres modèles *open source* pour identifier le meilleur compromis performance/coût dans le contexte bilingue camerounais.

4.1.5.2 Modèle d'embedding multilingue

Le modèle d'embedding conditionne la qualité du retrieval dense et, par conséquent, la pertinence des documents fournis au générateur. Le critère principal est la performance cross-

lingue FR/EN, mesurée sur les benchmarks MTEB [33] et BEIR [53].

Choix retenu : Qwen3-Embedding (avec BGE-M3 comme alternative). Le choix est motivé par la combinaison du meilleur score MTEB Retrieval parmi les modèles déployables localement, de la compatibilité avec la contrainte de souveraineté (C9), et de la continuité avec GOV-AI 1.0 [32] qui avait déjà validé ce modèle en contexte bilingue camerounais. BGE-M3 constitue une alternative solide grâce à son architecture multi-granularité (dense + sparse + multi-vector) et son support natif du français. Les modèles accessibles uniquement par API sont écartés pour des raisons de souveraineté. L'évaluation comparative sur un corpus juridique bilingue camerounais (chapitre 5) permettra de confirmer ou d'infirmer ce choix.

4.1.5.3 Base de données vectorielle

La base vectorielle stocke les embeddings des chunks documentaires et exécute les recherches par similarité. Les critères déterminants sont la performance en recherche ANN (*Approximate Nearest Neighbors*), la scalabilité, le support du filtrage par métadonnées, et la possibilité de déploiement souverain.

Choix retenu : Milvus. Ce choix est justifié par cinq arguments : validation préalable dans GOV-AI 1.0 [32], support natif de la recherche hybride, scalabilité à grande échelle, compromis recall/latence offert par HNSW, et maturité de l'écosystème.

4.1.5.4 Moteur de recherche lexicale (BM25)

La composante sparse de la recherche hybride nécessite un moteur de recherche lexicale performant.

Choix retenu : Elasticsearch (ou OpenSearch). Le choix est motivé par la richesse des analyseurs linguistiques pour le français et l'anglais, indispensables pour un corpus juridique bilingue.

4.1.5.5 Modèle de reranking (cross-encoder)

Le reranking est une étape critique qui réordonne les candidats du *first-stage retrieval*.

Choix retenu : cross-encoder multilingue dédié (Qwen3-Reranker, avec BGE-Reranker-v2 comme alternative) + pondération métadonnées séparée. Le cross-encoder offre le meilleur compromis entre qualité et latence.

4.1.5.6 Base de données graphe et couche ontologique

Choix retenu : Neo4j (Community Edition) + couche OWL via le plugin n10s. Ce choix hybride offre le meilleur compromis entre performances de traversée, rigueur formelle, écosystème IA et déploiement souverain.

4.1.5.7 Framework d'orchestration

Choix retenu : LangGraph (extension de LangChain). Ce choix est motivé par la continuité avec GOV-AI 1.0, la capacité à modéliser un graphe d'états avec cycles, et l'écosystème d'intégration existant.

4.1.5.8 Navigateur headless pour l'agent web

Choix retenu : Playwright. Ce choix est justifié par le rendu JavaScript complet, le support multi-navigateurs, l'API asynchrone native en Python et les capacités de sandboxing.

4.1.5.9 OCR et ASR

Choix retenu : Tesseract 5 (avec PaddleOCR comme alternative pour les documents à mise en page complexe). Tesseract est déjà validé dans GOV-AI 1.0.

Choix retenu : Whisper (*large-v3*). Ce choix est motivé par la qualité de reconnaissance multilingue FR/EN sans *fine-tuning*, la possibilité de déploiement local et la continuité avec GOV-AI 1.0.

4.1.5.10 Synthèse des choix technologiques

Le Tableau 4.16 récapitule l'ensemble des choix technologiques retenus et les contraintes qui les motivent.

Il convient de souligner que ces choix sont provisoires au sens scientifique : le protocole expérimental (section 4.5) prévoit des ablations et des comparaisons qui pourront conduire à réviser certains choix sur la base des résultats empiriques. En particulier, le choix du LLM et du modèle d'embedding sera validé par des benchmarks spécifiques au domaine juridique bilingue camerounais.

4.2 Données et constitution du corpus national

4.2.1 Sources documentaires

Le corpus de GOV-AI 2.0 comprend trois catégories de sources, toutes sous contrôle de l'État camerounais :

Corpus interne (CI). Textes juridiques et administratifs officiels : Constitution, codes (civil, pénal, commercial, du travail, de procédure), lois, ordonnances, décrets, arrêtés, circulaires, notes de service, guides de procédures, formulaires, organigrammes. Ce corpus est hérité de GOV-AI 1.0 et étendu. Formats : PDF natifs et scans. Langues : français et anglais.

Corpus OHADA. Actes uniformes de l'Organisation pour l'Harmonisation en Afrique du Droit des Affaires, applicables uniformément sur le territoire. Source : portail officiel ohada.org.

Corpus web autorisé (CW). Pages des sites institutionnels de la liste blanche, accessibles par l’agent web. Ce corpus est dynamique et horodaté à chaque consultation.

4.2.2 Pipeline d’ingestion

Le pipeline d’ingestion transforme les documents bruts en représentations indexées selon la séquence suivante :

$$(4.1) \quad d_{\text{brut}} \xrightarrow{f_{\text{extract}}} d_{\text{texte}} \xrightarrow{f_{\text{clean}}} d_{\text{propre}} \xrightarrow{f_{\text{chunk}}} \{c_1, \dots, c_m\} \xrightarrow{f_{\text{embed}}} \{(\mathbf{v}_1, \mathbf{m}_1), \dots, (\mathbf{v}_m, \mathbf{m}_m)\}$$

où f_{extract} désigne l’extraction textuelle, f_{clean} la normalisation, f_{chunk} la segmentation, f_{embed} la vectorisation, $\mathbf{v}_i \in \mathbb{R}^d$ le vecteur d’embedding du chunk c_i , et $\mathbf{m}_i$ le vecteur de métadonnées.

Stratégie de chunking. Chunking structurel pour les documents à structure formelle (chaque article = un chunk) et chunking à taille fixe avec overlap pour les documents non structurés (taille de référence : 512 tokens, overlap : 64 tokens). Une stratégie *parent-child* est implémentée.

Double indexation. Chaque chunk est stocké dans : (i) un index vectoriel Milvus et (ii) un index BM25 Elasticsearch. Les métadonnées permettent le filtrage pré-retrieval.

4.2.3 Versioning et horodatage

Chaque document et chunk porte une date d’ingestion et un identifiant de version. Le système conserve l’historique des versions pour permettre la traçabilité temporelle. Un pipeline d’ingestion continue surveille les sources officielles et intègre les nouveaux textes de manière hebdomadaire ou déclenchée par publication.

4.3 Pipeline de réalisation : de la requête à la réponse

4.3.1 Algorithme 1 — Orchestrateur cognitif (routage d’intention et sélection d’outils)

L’orchestrateur cognitif est le composant central. Il reçoit la requête normalisée, consulte les mémoires, planifie les actions et coordonne les sous-agents.

ALGORITHME 1 : Orchestrateur cognitif GOV-AI 2.0

Entrée : requête q , profil utilisateur u , historique session H , outils $T = \text{RAG, Web, Graphe, Mémoire, modèle } M$, seuils $(\tau_{\text{conf}}, \tau_{\text{esc}})$ Sortie : réponse r avec citations C , avertissements W

1. [PERCEVOIR] $\text{lang} \leftarrow \text{détecterLangue}(q)$ $\text{entités} \leftarrow \text{extraireEntités}(q)$ $\text{intention} \leftarrow \text{classifierIntention}(q)$

2. [COMPRENDRE] $\text{profil} \leftarrow \text{chargerProfil}(u)$ $\text{ctx_session} \leftarrow \text{résumé}(H)$ $\text{mém_épistodique} \leftarrow \text{rechercherMémoireÉpistodique}(u, q)$
3. [DÉLIBÉRER] $\text{plan} \leftarrow M.\text{planifier}(q, \text{intention}, \text{entités}, \text{profil}, \text{ctx_session})$
4. [AGIR] $\text{résultats} \leftarrow []$ POUR CHAQUE $(\text{outil}, \text{params})$ DANS plan : SI $\text{outil} = \text{RAG}$: $\text{chunks} \leftarrow \text{retrievalHybride}(q, \text{params})$ $\text{résultats.ajouter}(\text{chunks})$ SI $\text{outil} = \text{Graphe}$: $\text{faits} \leftarrow \text{requêteGraphe}(q, \text{entités}, \text{params})$ $\text{résultats.ajouter}(\text{faits})$ SI $\text{outil} = \text{Web}$: $\text{extraits} \leftarrow \text{agentWeb}(q, \text{params})$ $\text{résultats.ajouter}(\text{extraits})$ SI $\text{outil} = \text{Mémoire}$: $\text{rappels} \leftarrow \text{rappelMémoire}(u, q)$ $\text{résultats.ajouter}(\text{rappels})$ $\text{journaliser}(\text{outil}, \text{params}, \text{résultats}[-1])$
5. [GÉNÉRER] $\text{contexte} \leftarrow \text{assembler}(\text{résultats}, \text{profil})$ $\text{r_brut} \leftarrow M.\text{générer}(q, \text{contexte}, \text{profil}, \text{lang})$
6. [VÉRIFIER] $(r, C, W, \text{score_conf}) \leftarrow \text{vérifier}(\text{r_brut}, \text{résultats})$ SI $\text{score_conf} < \tau_{\text{esc}}$: $r \leftarrow \text{messageEscalade}(q, \text{résumé}(\text{résultats}))$ $W.\text{ajouter}(\text{"Escalade recommandée"})$ SINON SI $\text{score_conf} < \tau_{\text{conf}}$: $W.\text{ajouter}(\text{"Confiance limitée — vérifiez auprès du service compétent"})$
7. [ADAPTER] $\text{mettreÀJourMémoireÉpistodique}(u, q, r, \text{score_conf})$ $\text{mettreÀJourProfilSiConsenti}(u, \text{entités})$ $\text{journaliser}(q, r, C, W, \text{score_conf}, \text{plan})$
8. RETOURNER (r, C, W)

4.3.2 Algorithme 2 — Retrieval hybride avec fusion et reranking

ALGORITHME 2 : Retrieval hybride + reranking

Entrée : requête q , paramètres $(k_{\text{sparse}}, k_{\text{dense}}, k_{\text{rerank}}, k_{\text{final}}, \alpha, \beta, \text{filtres } F)$ Sortie : chunks ordonnés C_{final} avec scores

1. [RÉÉCRITURE] $q_{\text{exp}} \leftarrow M.\text{expanderRequête}(q)$ SI $\text{requêteComplexe}(q)$: $q_1, \dots, q_p \leftarrow M.\text{décomposer}(q)$
2. [RECHERCHE SPARSE] $R_{\text{sparse}} \leftarrow \text{BM25}(q_{\text{exp}}, k_{\text{sparse}}, F)$
3. [RECHERCHE DENSE] $v_q \leftarrow \text{Embed}(q_{\text{exp}})$ $R_{\text{dense}} \leftarrow \text{Milvus.search}(v_q, k_{\text{dense}}, F)$
4. [FUSION RRF] POUR CHAQUE $\text{chunk } c \in R_{\text{sparse}} \cup R_{\text{dense}}$: $\text{RRF}(c) = \sum_{r \in \text{sparse}, \text{dense}} 1 / (60 + \text{rang}_r(c))$
5. [RERANKING] $C_k \leftarrow \text{top-}k_{\text{rerank}}(\text{RRF})$ POUR CHAQUE $c_i \in C_k$: $s_{\text{rerank}}(q, c_i) \leftarrow \text{CrossEncoder}([q; \text{SEP}; c_i])$ $s_{\text{final}}(q, c_i) \leftarrow s_{\text{rerank}}(q, c_i) + \beta \cdot w_{\text{meta}}(c_i)$
6. $C_{\text{final}} \leftarrow \text{top-}k_{\text{final}}(\text{sort}(C_k, \text{key}=s_{\text{final}}, \text{desc}))$
7. RETOURNER C_{final}

La pondération des métadonnées est définie par :

$$(4.2) \quad s_{\text{final}}(q, c_i) = s_{\text{rerank}}(q, c_i) + \beta \cdot w_{\text{meta}}(c_i)$$

4.3.3 Algorithme 3 — Agent web contrôlé

ALGORITHME 3 : Agent web contrôlé

Entrée : requête q , liste blanche LB , budget d'actions K_max , seuil confiance τ_web Sortie : extraits web E avec citations structurées, contradictions détectées

1. [VÉRIFICATION DOMAINE] $requête_search \leftarrow M.formulerRecherche(q)$
 2. [RECHERCHE] $résultats \leftarrow moteurRecherche(requête_search)$ $résultats \leftarrow filtrer(résultats, domaine \in LB)$ SI $résultats = \emptyset$: RETOURNER $(\emptyset, "Aucune source autorisée trouvée")$
 3. [NAVIGATION ET EXTRACTION] $E \leftarrow []$ actions $\leftarrow 0$ POUR CHAQUE $url \in résultats$ ET actions $< K_max$: $page \leftarrow navigateurHeadless.charger(url)$ $contenu \leftarrow extraireTexte(page)$ $contenu \leftarrow filtrerInjection(contenu)$ $passages \leftarrow M.extrairePassagesPertinents(q, contenu)$ POUR CHAQUE $p \in passages$: $citation \leftarrow url, titre_page, date_publication, date_accès, institution$ $E.ajouter((p, citation))$ actions $\leftarrow actions + 1$
 4. [SCORING CONFIANCE] POUR CHAQUE $(p, cit) \in E$: $c(p) = \alpha \cdot autorité(cit) + \beta \cdot fraîcheur(cit) + \gamma \cdot cohérence(p, corpus_interne)$ $E \leftarrow filtrer(E, c(p) \geq \tau_web)$
 5. [DÉTECTION DE CONTRADICTIONS] POUR CHAQUE $(p, cit) \in E$: $chunks_internes \leftarrow RAG.rechercher(sujet(p), k=3)$ SI $contradiction(p, chunks_internes)$: $E.marquer(p, "CONFLIT", chunks_internes)$
 6. $journaliser(requête_search, urls_accédées, E, actions)$ RETOURNER E
- Le score de confiance des sources web est donné par :

$$(4.3) \quad c(s) = \alpha \cdot autorité(s) + \beta \cdot fraîcheur(s) + \gamma \cdot cohérence(s, corpus_interne)$$

4.3.4 Algorithme 4 — Génération contrainte par citations

ALGORITHME 4 : Génération contrainte par citations (citing-by-design)

Entrée : requête q , contexte ctx (chunks + faits graphe + extraits web), profil u , langue $lang$ Sortie : réponse r_brut avec citations inline

1. [CONSTRUCTION DU PROMPT] $prompt_system \leftarrow construireSystemPrompt(lang, profil.niveauDétail)$ $prompt_context \leftarrow formater(ctx, avec_métadonnées=True)$ $prompt_user \leftarrow q$
2. [GÉNÉRATION] $r_brut \leftarrow LLM.générer(prompt_system + prompt_context + prompt_user, streaming=True, température=0.1)$
3. RETOURNER r_brut

4.3.5 Algorithme 5 — Détection d'incertitude et vérification

ALGORITHME 5 : Vérification et détection d'incertitude

Entrée : réponse r_brut , contexte ctx (chunks + extraits), seuils (τ_conf, τ_cit) Sortie : réponse vérifiée r , citations validées C , avertissements W , score_conf

1. [DÉCOMPOSITION EN ASSERTIONS] $A \leftarrow décomposerEnAssertions(r_brut)$

2. [VÉRIFICATION ASSERTION PAR ASSERTION] $C \leftarrow []$, $W \leftarrow []$, $n_supportées \leftarrow 0$ POUR CHAQUE $a_i \in A$: $support \leftarrow rechercherSupport(a_i, ctx)$ SI $support.trouvé$: $C.ajouter(support.source)$ $n_supportées \leftarrow n_supportées + 1$ SINON : $W.ajouter("Assertion non supportée : " + a_i)$ $r_brut \leftarrow supprimerOuMarquer(r_brut, a_i)$

3. [CALCUL DU SCORE DE GROUNDEDNESS] $groundedness \leftarrow n_supportées / |A|$

4. [DÉTECTION DE CONTRADICTIONS INTERNES] SI $contradictionsDétectées(A)$: $W.ajouter("Contradictions entre sources détectées")$

5. [CALCUL DU SCORE DE CONFIANCE AGRÉGÉ] $score_retrieval \leftarrow moyenne(scores_pertinence(ctx))$ $score_conf \leftarrow \omega_1 \cdot groundedness + \omega_2 \cdot score_retrieval$

6. [APPLICATION DE LA POLITIQUE DE REFUS] SI $score_conf < \tau_conf$: $r \leftarrow ajouterAver-tissement(r_brut, "Confiance limitée")$ $r \leftarrow r_brut$

7. RETOURNER (r , C , W , $score_conf$)

Le score de groundedness est défini comme :

$$(4.4) \quad \text{Groundedness}(r, C) = \frac{|a_i \in A : \exists c \in C, \text{supports}(c, a_i)|}{|A|}$$

Le score de confiance agrégé combine groundedness et qualité du retrieval :

$$(4.5) \quad score_conf = \omega_1 \cdot \text{Groundedness}(r, C) + \omega_2 \cdot \bar{s}_{\text{retrieval}}$$

4.3.6 Algorithme 6 — Politique de mémoire (write / read / prune / forget)

ALGORITHME 6 : Politique de mémoire

Entrée : interaction (u , q , r), consentement c_u , politique $P(\text{durée}, \text{seuils})$ Sortie : mémoire mise à jour $M(u)$

— WRITE — 1. SI $c_u.mémoireAutorisée = \text{False}$: NE RIEN STOCKER RETOURNER

2. $importance \leftarrow M.évaluerImportance(q, r)$ SI $importance \geq P.\theta_write$: $entrée \leftarrow \text{contenu} : \text{résumé}(q, r), \text{timestamp} : \text{now}(), \text{importance} : importance$ $M(u).épisode.insérer(entrée)$ $\text{journaliser("WRITE", } u, \text{hash}(entrée))$

3. SI $\text{nouvellesInfoProfil}(q, r, \text{entités})$ ET $c_u.profilAutorisé$: $M(u).profil.mettreÀJour(\text{extraireInfoProfil}(q, r))$ $\text{journaliser("PROFILE_UPDATE", } u)$

— READ — 4. $M_relevant(u, q) \leftarrow \text{top-k}(\text{score}(m_i, q, t) \mid m_i \in M(u).épisode)$

— PRUNE — 5. POUR CHAQUE $m_i \in M(u).épisode$: SI $\text{récence}(m_i, \text{now}()) < P.\theta_decay$: SI $importance(m_i) \geq P.\theta_consolidation$: $M(u).épisode.consolider(m_i)$ SINON : $M(u).épisode.supprimer(m_i)$ $\text{journaliser("PRUNE", } u, \text{hash}(m_i))$

— FORGET — 6. SI $\text{demandeOubli}(u)$: $M(u).épisode.purgerTout()$ $M(u).profil.réinitialiser()$ $\text{journaliser("FORGET_REQUEST", } u)$

4.4 Protocole expérimental

4.4.1 Construction du jeu de questions (dataset)

Un jeu de questions bilingue est construit selon les spécifications suivantes :

- **Volume cible** : 200 questions (100 FR, 100 EN), réparties par domaine et par profil.
- **Annotation** : chaque question est associée à une réponse de référence rédigée par un expert, avec identification des sources pertinentes.
- **Types de requêtes** : factuelles simples, procédurales, comparatives bijuridiques, hors corpus, multi-tours.
- **Double annotation** : au moins deux annotateurs par question ; accord inter-annotateurs mesuré par le kappa de Cohen [7].

4.4.2 Baselines et configurations (ablations incrémentales)

Six configurations sont définies pour mesurer l’apport incrémental de chaque composant. La configuration B5 complète correspond à GOV-AI 2.0 et permet de tester H4.

4.4.3 Scénarios d’évaluation

Trois scénarios sont définis :

Scénario S1 — Questions standard. Questions factuelles et procédurales dont la réponse se trouve dans le corpus interne. Évalue B0–B3.

Scénario S2 — Questions nécessitant le web. Questions dont la réponse est absente du corpus interne ou potentiellement obsolète. Évalue B4 vs. B3.

Scénario S3 — Conversations multi-tours. Séquences de 3 à 5 questions nécessitant le maintien du contexte et la personnalisation. Évalue B5 vs. B4.

4.5 Métriques et critères d’évaluation

Métriques de retrieval (couche IR)

Recall@k :

$$(4.6) \quad \text{Recall}@k(q) = \frac{|\{d \in R_k(q) : \text{rel}(d, q) = 1\}|}{|\{d \in D : \text{rel}(d, q) = 1\}|}$$

MRR :

$$(4.7) \quad \text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{\text{rang}_1(q)}$$

nDCG@k :

$$(4.8) \quad \text{nDCG}@k(q) = \frac{\text{DCG}@k(q)}{\text{IDCG}@k(q)}, \quad \text{DCG}@k = \sum_{i=1}^k \frac{2^{\text{rel}(d_i, q)} - 1}{\log_2(i + 1)}$$

4.5.1 Métriques de génération

Les métriques de génération incluent : exactitude, groundedness, taux d'hallucination, complétude et Citation Precision. Les seuils cibles sont : exactitude $\geq 85\%$, groundedness $\geq 95\%$, hallucination $\leq 5\%$, Citation Precision $\geq 95\%$.

4.5.2 Métriques de l'agent web

Les métriques incluent :

- **Task Success Rate** : seuil cible $\geq 80\%$.
- **Conformité des sources** : taux de sorties hors liste blanche = 0% .
- **Nombre d'actions moyen** et temps moyen par tâche.

Métriques de mémoire

La cohérence multi-tour est définie par :

$$(4.9) \quad \text{Cohérence} = \frac{\text{Réponses cohérentes avec le contexte mémorisé}}{\text{Total réponses nécessitant un rappel mémoriel}}$$

Les autres métriques incluent Memory Recall@k et le taux de confusion d'utilisateur (seuil cible : 0%).

Métriques de performance système

Les métriques de performance incluent la latence p50 / p95 et le coût par requête. Les seuils cibles sont : p50 $\leq 3\text{s}$ (RAG), $\leq 8\text{s}$ (web); p95 $\leq 8\text{s}$ (RAG), $\leq 20\text{s}$ (web).

4.5.3 Métriques d'équité bilingue

L'Indice de Symétrie Bilingue (ISB) est défini par :

$$(4.10) \quad \text{ISB} = \frac{\min(S_{\text{FR}}, S_{\text{EN}})}{\max(S_{\text{FR}}, S_{\text{EN}})}$$

Seuil cible : $\text{ISB} \geq 0,85$.

4.5.4 Métriques UX (optionnel)

Les métriques UX incluent le SUS (*System Usability Scale*) [6], avec un seuil cible $\geq 70/100$, et le taux de résolution au premier contact ($\geq 75\%$).

4.5.5 Synthèse des métriques

4.6 Comparaison prévue avec les solutions existantes

La stratégie de comparaison repose sur trois niveaux.

Niveau 1 — Comparaison interne (ablations). Les six configurations B0–B5 sont évaluées sur le même jeu de questions avec les mêmes métriques. Cette comparaison contrôlée permet de quantifier l’apport de chaque composant et de tester les hypothèses H1–H4.

Niveau 2 — Comparaison avec GOV-AI 1.0. La configuration B1 (RAG simple) approxime le fonctionnement de GOV-AI 1.0 [32]. La comparaison B1 vs. B5 mesure le gain global apporté par GOV-AI 2.0.

Niveau 3 — Comparaison avec les benchmarks de l’état de l’art. Les modèles d’embeddings utilisés sont évalués sur MTEB [33] et BEIR [53]. Les résultats de l’agent web sont comparés à WebArena [64]. Le cadre RAGAS [11] est utilisé pour positionner la qualité du pipeline RAG.

4.7 Mini-conclusion du chapitre

Ce chapitre a défini la méthodologie complète de GOV-AI 2.0 selon trois axes. Premièrement, l’architecture cible a été spécifiée comme un système cognitif agentique intégrant orchestrateur, RAG interne, agent web, graphe de connaissances et mémoire hiérarchique, avec un mappage explicite entre phases cognitives et composants techniques. Six algorithmes critiques ont été formalisés : orchestrateur cognitif, retrieval hybride avec reranking, agent web contrôlé, génération contrainte par citations, détection d’incertitude et vérification, et politique de mémoire. Deuxièmement, un protocole expérimental à six configurations incrémentales a été défini, avec un jeu de questions bilingue annoté et des métriques multi-niveaux couvrant retrieval, génération, agent web, mémoire, performance et équité. Troisièmement, une stratégie de comparaison à trois niveaux (ablations internes, comparaison avec GOV-AI 1.0, positionnement par rapport aux benchmarks) permettra de tester les quatre hypothèses de recherche et de quantifier l’apport de l’approche endogène proposée.

TABLE 4.2 – Éléments repris de l'état de l'art et du prototype GOV-AI 1.0

Composant	Repris de	Adaptation GOV-AI 2.0
Pipeline RAG (embedding, indexation, retrieval, génération)	Lewis <i>et al.</i> [28], GOV-AI 1.0 [32]	Ajout de BM25 pour recherche hybride, reranking cross-encoder, citations obligatoires
Modèle d'embedding multilingue (Qwen3-Embedding)	GOV-AI 1.0 [32]	Conservé; évaluation MTEB cross-lingue FR/EN prévue
Indexation vectorielle (Milvus + HNSW)	GOV-AI 1.0 [32]	Conservée; ajout index BM25 (Elasticsearch/Lucene) pour hybridation
Boucle raisonnement-action (ReAct)	Yao <i>et al.</i> [61]	Intégrée dans l'orchestrateur avec planification préalable pour requêtes complexes
Agent web (recherche + navigation)	WebGPT [34], ReAct [61]	Restreint à liste blanche, <i>citing-by-design</i> , détection de contradictions
Ontologie juridique	LKIF Core [19], LegalRuleML [45]	Spécialisation pour bijuridisme camerounais (3 niveaux), bilinguisme natif
Mémoire hiérarchique	MemGPT [44], Generative Agents [47]	Scoring composite (récence + importance + pertinence), politiques de confidentialité secteur public
Cadre de risques	NIST AI RMF [35], OWASP [43]	Application systématique au contexte camerounais

TABLE 4.3 – Comparaison des modèles de langage candidats

Critère	GPT-4o	Claude 3.5	Llama 3.1 70B	Qwen 2.5 72B	Mistral Large
Performance générale (MMLU)	~88 %	~87 %	~82 %	~83 %	~81 %
Support FR/EN	Excellent	Excellent	Bon	Bon	Très bon
Déploiement local (<i>on-premise</i>)	Non	Non	Oui (Apache 2.0)	Oui (Apache 2.0)	Oui (Apache 2.0)
Souveraineté (C9)	×	×	✓	✓	✓
Coût par requête estimé	~0,03–0,10 USD	~0,03–0,08 USD	Infrastructure locale	Infrastructure locale	Infrastructure locale
Function calling natif	Oui	Oui	Oui	Oui	Oui
Fenêtre de contexte	128K tokens	200K tokens	128K tokens	128K tokens	128K tokens
Quantification (QLoRA/GGUF)	N/A	N/A	Oui (4-bit viable)	Oui (4-bit viable)	Oui (4-bit viable)
Licence	Propriétaire	Propriétaire	Apache 2.0	Apache 2.0	Apache 2.0

TABLE 4.4 – Comparaison des modèles d’embedding multilingues

Critère	Qwen3-Embedding	multilingual-e5-large	BGE-M3	Cohere embed-v3	Voyage-3
Score MTEB Retrieval	64,65	61,50	63,55	64,30	63,80
Dimensions du vecteur	1024	1024	1024	1024	1024
Support cross-lingue FR↔EN	Bon	Bon	Très bon	Très bon	Bon
Taille du modèle	0,6B	0,56B	0,57B	N/A (API)	N/A (API)
Déploiement local	Oui	Oui	Oui	Non	Non
Souveraineté (C9)	✓	✓	✓	×	×
Licence	Apache 2.0	MIT	MIT	Propriétaire	Propriétaire
Support requêtes longues	8192 tokens	512 tokens	8192 tokens	512 tokens	8192 tokens

TABLE 4.5 – Comparaison des bases de données vectorielles

Critère	Milvus	Qdrant	Weaviate	Pinecone	Chroma	pgvector
Algorithme ANN	HNSW, IVF, DiskANN	HNSW	HNSW	Propriétaire	HNSW	IVFFlat, HNSW
Filtrage méta-données	Oui	Oui	Oui	Oui	Limité	Oui
Scalabilité	Milliards	Millions	Millions	Milliards	Milliers–Millions	Millions
Déploiement <i>on-premise</i>	Oui	Oui	Oui	Non	Oui	Oui
Recherche hybride	Oui	Oui	Oui	Oui	Non	Non natif
Intégration LangChain	Oui	Oui	Oui	Oui	Oui	Oui
Maturité / communauté	Élevée	Moyenne	Moyenne	Élevée	Faible–Moyenne	Élevée
Licence	Apache 2.0	Apache 2.0	BSD-3	Propriétaire	Apache 2.0	PostgreSQL
Souveraineté (C9)	✓	✓	✓	×	✓	✓

TABLE 4.6 – Comparaison des moteurs de recherche lexicale

Critère	Elasticsearch	Apache Solr	Milvus BM25 intégré	Typesense
Performance BM25	Référence	Comparable	Récent	Bonne
Analyse linguistique FR/EN	Oui	Oui	Basique	Limitée
Synonymes / stemming FR	Oui	Oui	Non	Limité
Scalabilité	Très élevée	Très élevée	Liée à Milvus	Moyenne
Filtrage méta-données	Oui	Oui	Oui	Oui
Déploiement <i>on-premise</i>	Oui	Oui	Oui	Oui
Licence	SSPL / Apache 2.0 (Open-Search)	Apache 2.0	Apache 2.0	GPL-3
Communauté	Très large	Large	En croissance	Moyenne

TABLE 4.7 – Comparaison des approches de reranking

Critère	Cross- encoder dédié	Cohere Re- rank	Reranking par LLM
Qualité (gain nDCG)	Élevée	Élevée	Variable
Latence (k=20)	~100–300 ms	~200–500 ms	~1–3 s
Support multilingue FR/EN	Bon	Très bon	Dépend du LLM
Déploiement local	Oui	Non	Oui
Coût	Infrastructure locale	API	Coût infé- rence LLM
Souveraineté (C9)	✓	×	✓
Intégration métadon- nées	Limitée	Non	Oui

TABLE 4.8 – Comparaison des technologies de graphe de connaissances

Critère	Neo4j n10s	Triple store RDF	Amazon Neptune	ArangoDB
Performance tra- versée	Excellente	Moyenne	Bonne	Bonne
Raisonnement OWL	Via n10s + externe	Natif	Limité	Non
Langage de re- quête	Cypher + SPARQL	SPARQL	SPARQL / Gremlin	AQL
Intégration IA	Excellente	Limitée	Moyenne	Limitée
Visualisation	Neo4j Browser	Externe	Console AWS	UI ArangoDB
Déploiement <i>on- premise</i>	Oui	Oui	Non	Oui
Souveraineté (C9)	✓	✓	×	✓
Licence	GPL-3 / Commer- ciale	Variable	Propriétaire	Apache 2.0

TABLE 4.9 – Comparaison des frameworks d’orchestration d’agents

Critère	LangGraph	AutoGen	CrewAI	Custom Python
Modèle de contrôle	Graphe d’états	Multi-agents conversationnels	Rôles	Libre
Boucles itératives	Natif	Oui	Oui	À implémenter
Intégration outils	Excellente	Bonne	Moyenne	Libre
Traçabilité	Bonne	Basique	Basique	À implémenter
Flexibilité	Élevée	Moyenne	Faible	Maximale
Courbe d’apprentissage	Moyenne	Moyenne	Faible	Élevée
Maturité	En croissance rapide	Moyenne	Faible	N/A
Continuité GOV-AI 1.0	✓	×	×	×

TABLE 4.10 – Comparaison des navigateurs headless

Critère	Playwright	Puppeteer	Selenium	Requests + BeautifulSoup
Rendu JavaScript	Oui	Oui	Oui	Non
Multi-navigateurs	Oui	Limité	Oui	N/A
Performance	Rapide	Rapide	Plus lente	Très rapide
API asynchrone Python	Oui	Limité	Non	Oui
Isolation / sandboxing	Oui	Limité	Limité	N/A
Interception réseau	Oui	Oui	Limité	Non

TABLE 4.11 – Comparaison des solutions OCR

Critère	Tesseract 5	EasyOCR	PaddleOCR	Google Cloud Vision	Amazon Textract
Qualité FR/EN	Bonne	Bonne	Très bonne	Excellente	Excellente
Déploiement local	Oui	Oui	Oui	Non	Non
Support mise en page complexe	Limité	Limité	Bon	Excellent	Excellent
Licence	Apache 2.0	Apache 2.0	Apache 2.0	Propriétaire	Propriétaire
Souveraineté (C9)	✓	✓	✓	×	×

TABLE 4.12 – Comparaison des solutions ASR

Critère	Whisper	Wav2Vec 2.0	Google Speech-to-Text	Azure Speech
Qualité FR/EN	Excellente	Bonne	Excellente	Excellente
Déploiement local	Oui	Oui	Non	Non
Taille modèle	1,5B paramètres	Variable	N/A	N/A
Souveraineté (C9)	✓	✓	×	×

TABLE 4.13 – Synthèse des choix technologiques et contraintes associées

Composant	Technologie retenue	Alternative(s)	Contraintes déterminantes	Justification principale
LLM (génération)	Llama 3.1 70B	Qwen 2.5 72B, Mistral Large	C7, C9	Souveraineté + performances FR/EN + <i>open source</i>
Embedding	Qwen3-Embedding	BGE-M3	C1, C9	Meilleur score MTEB localement ; validé GOV-AI 1.0
Base vectorielle	Milvus (HNSW)	Qdrant, Weaviate	C6, C8, C9	Recherche hybride native ; validé GOV-AI 1.0 ; scalabilité
Recherche lexicale	Elasticsearch / OpenSearch	Solr, Milvus BM25	C1	Analyseurs linguistiques FR/EN matures
Reranker	Qwen3-Reranker	BGE-Reranker-v2	C1, C6, C9	Cross-encoder multilingue performant ; local
Graphe de connaissances	Neo4j + n10s (OWL)	GraphDB, ArangoDB	C2, C5	Performance traversée + rigueur OWL + écosystème IA
Orchestration	LangGraph	AutoGen, custom	Continuité GOV-AI 1.0	Graphe d'états avec cycles ; connecteurs natifs
Navigateur headless	Playwright	Selenium, Puppeteer	C4, C6	Rendu JS + sandboxing + async Python
OCR	Tesseract 5	PaddleOCR	C9	Validé GOV-AI 1.0 ; <i>open source</i>
ASR	Whisper large-v3	Wav2Vec 2.0	C1, C9	Multilingue natif FR/EN ; local
Détection de langue	Langdetect	FastText langid	C1	Léger, rapide, validé GOV-AI 1.0
NLI (contradictions)	mDeBERTa-v3-xnli	LLM-as-Judge	C3, C4	Spécialisé NLI ; faible latence

TABLE 4.14 – Configurations expérimentales (baselines et ablations)

Config.	Description	Composants actifs	Hypothèse testée
B0	Recherche lexicale pure	BM25 + extraction de passages (sans LLM)	—
B1	RAG simple	Dense retrieval + LLM (sans re-ranking ni vérification)	—
B2	RAG amélioré	Hybride (BM25+dense) + reranking + citations obligatoires	H1
B3	B2 + Ontologie/Graphe	B2 + enrichissement requête par KG + recherche parallèle graphe	—
B4	B3 + Agent Web	B3 + agent web contrôlé (sites officiels)	H2
B5	B4 + Mémoire	B4 + mémoire hiérarchique (session + épisodique + profil)	H3

TABLE 4.15 – Synthèse des métriques d'évaluation

Niveau	Métrique	Seuil cible	Configurations évaluées	Hypothèse testée
Retrieval	Recall@20, MRR, nDCG@10	$R@20 \geq 0,85$	B0–B5	H1
Génération	Exactitude, Groundedness, Hallucination Rate, Citation Precision	Exact. $\geq 85\%$, Ground. $\geq 95\%$, Hall. $\leq 5\%$	B1–B5	H1
Agent web	Task Success Rate, Conformité sources	TSR $\geq 80\%$, Conform. = 100 %	B4, B5	H2
Mémoire	Cohérence multi-tour, Memory Recall@k	Cohér. $\geq 97\%$, Confusion = 0 %	B5	H3
Performance	Latence p50/p95	$p50 \leq 3s$ (RAG)	Toutes	—
Équité	ISB	$\geq 0,85$	Toutes	—

TABLE 4.16 – Plan de comparaison

Niveau	Objet de comparaison	Métriques utilisées	Objectif
Interne (ablations)	B0 vs. B1 vs. B2 vs. B3 vs. B4 vs. B5	Toutes (Tableau 4.4)	Quantifier l'apport de chaque composant
GOV-AI 1.0	B1 ($\approx$ GOV-AI 1.0) vs. B5 (GOV-AI 2.0)	Exactitude, Groundedness, Hallucination, Latence	Démontrer le progrès
État de l'art	Embeddings vs. MTEB; Agent vs. WebArena; RAG vs. RAGAS	Recall@k, TSR, Faithfulness	Positionnement scientifique

BIBLIOGRAPHIE

- [1] E. A. ANCHIMBE, *Cameroon English : Authenticity, Ecology and Evolution*, Peter Lang, Frankfurt am Main, 2006.
- [2] J. R. ANDERSON, D. BOTHELL, M. D. BYRNE, S. DOUGLASS, C. LEBIERE, AND Y. QIN, *An integrated theory of the mind*, *Psychological Review*, 111 (2004), pp. 1036–1060.
- [3] ANTHROPIC, *The Claude model card*, tech. rep., Anthropic, 2024. Version 3.
- [4] A. ASAI, Z. WU, Y. WANG, A. SIL, AND H. HAJISHIRZI, *Self-RAG : Learning to retrieve, generate, and critique through self-reflection*, in *The Twelfth International Conference on Learning Representations (ICLR 2024)*, 2024.
- [5] B. J. BAARS, *A Cognitive Theory of Consciousness*, Cambridge University Press, Cambridge, 1988.
- [6] J. BROOKE, *SUS : A quick and dirty usability scale*, in *Usability Evaluation in Industry*, P. W. Jordan, B. Thomas, B. A. Weerdmeester, and A. L. McClelland, eds., Taylor & Francis, London, 1996, pp. 189–194.
- [7] J. COHEN, *A coefficient of agreement for nominal scales*, *Educational and Psychological Measurement*, 20 (1960), pp. 37–46.
- [8] G. V. CORMACK, C. L. A. CLARKE, AND S. BUETTCHER, *Reciprocal rank fusion outperforms Condorcet and individual rank learning methods*, in *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2009, pp. 758–759.
- [9] M. DAHL, V. MAGESH, M. SUZGUN, AND D. E. HO, *Large legal fictions : Profiling legal hallucinations in large language models*, *Journal of Legal Analysis*, 16 (2024), pp. 64–93.
- [10] X. DENG, Y. GU, B. ZHENG, S. CHEN, S. STEVENS, B. WANG, H. SUN, AND Y. SU, *Mind2Web : Towards a generalist agent for the web*, in *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*, 2023.

- [11] S. ES, J. JAMES, L. ESPINOSA-ANKE, AND S. SCHOCKAERT, *RAGAS : Automated evaluation of retrieval augmented generation*, in Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL 2024), 2024, pp. 150–163.
- [12] S. FRANKLIN, T. MADL, S. D’MELLO, AND J. SNAIDER, *LIDA : A systems-level theory of mind*, in Proceedings of the Second Conference on Artificial General Intelligence, 2007, pp. 169–177.
- [13] L. GAO, Z. DAI, P. PASUPAT, A. CHEN, A. T. CHAGANTY, Y. FAN, V. Y. ZHAO, N. LAO, H. LEE, D.-C. JUAN, AND K. GUU, *RARR : Researching and revising what language models say, using language models*, in Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), 2023, pp. 16477–16508.
- [14] Z. GOU, Z. SHAO, Y. GONG, Y. SHEN, Y. YANG, N. DUAN, AND W. CHEN, *CRITIC : Large language models can self-correct with tool-interactive critiquing*, in The Twelfth International Conference on Learning Representations (ICLR 2024), 2024.
- [15] K. GRESHAKE, S. ABDELNABI, S. MISHRA, C. ENDRES, T. HOLZ, AND M. FRITZ, *Not what you’ve signed up for : Compromising real-world LLM-integrated applications with indirect prompt injection*, in Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISec 2023), 2023, pp. 79–90.
- [16] T. R. GRUBER, *A translation approach to portable ontology specifications*, Knowledge Acquisition, 5 (1993), pp. 199–220.
- [17] N. GUHA, J. NYARKO, D. E. HO, C. RÉ, A. CHILTON, A. NARAYANA, A. CHOHLAS-WOOD, A. PETERS, B. WALDON, D. N. ROCKMORE, D. ZAMBRANO, D. TALISMAN, E. HOQUE, F. SURANI, F. FAGAN, G. SARFATY, G. M. DICKINSON, H. PORAT, J. HEGLAND, J. WU, J. NUDELL, J. NIKLAUS, J. NAY, J. H. CHOI, K. TOBIA, M. HAGAN, M. MA, M. LIVERMORE, N. RASUMOV-RAHE, N. HOLZENBERGER, N. KOLT, P. HENDERSON, S. REHAAG, S. GOEL, S. GAO, S. WILLIAMS, S. GANDHI, T. ZUR, V. IYER, AND Z. LI, *LegalBench : A collaboratively built benchmark for measuring legal reasoning in large language models*, in Advances in Neural Information Processing Systems 36 (NeurIPS 2023), 2023.
- [18] A. R. HEVNER, S. T. MARCH, J. PARK, AND S. RAM, *Design science in information systems research*, MIS Quarterly, 28 (2004), pp. 75–105.
- [19] R. HOEKSTRA, J. BREUKER, M. D. BELLO, AND A. BOER, *The LKIF core ontology of basic legal concepts*, in Proceedings of the 2nd Workshop on Legal Ontologies and Artificial Intelligence Techniques (LOAIT 2007), 2007, pp. 43–63.

-
- [20] A. HOGAN, E. BLOMQVIST, M. COCHEZ, C. D’AMATO, G. DE MELO, C. GUTIERREZ, S. KIRANE, J. E. L. GAYO, R. NAVIGLI, S. NEUMAIER, A.-C. N. NGOMO, A. POLLERES, S. M. RASHID, A. RULA, L. SCHMELZEISEN, J. SEQUEDA, S. STAAB, AND A. ZIMMERMANN, *Knowledge graphs*, ACM Computing Surveys, 54 (2021), pp. 1–37.
 - [21] Z. JI, N. LEE, R. FRIESKE, T. YU, D. SU, Y. XU, E. ISHII, Y. J. BANG, A. MADOTTO, AND P. FUNG, *Survey of hallucination in natural language generation*, ACM Computing Surveys, 55 (2023), pp. 1–38.
 - [22] S. KADAVATH, T. CONERLY, A. ASKELL, T. HENIGHAN, D. DRAIN, E. PEREZ, N. SCHIEFER, Z. HATFIELD-DODDS, N. DASARMA, E. TRAN-JOHNSON, S. JOHNSTON, S. EL-SHOWK, A. JONES, N. ELHAGE, T. HUME, A. CHEN, Y. BAI, S. BOWMAN, S. FORT, D. GANGULI, D. HERNANDEZ, J. JACOBSON, J. KERNION, S. KRAVEC, L. LOVITT, K. NDOUSSE, C. OLSSON, S. RINGER, D. AMODEI, T. BROWN, J. CLARK, N. JOSEPH, B. MANN, S. MCCANDLISH, C. OLAH, AND J. KAPLAN, *Language models (mostly) know what they know*, 2022.
arXiv preprint arXiv :2207.05221.
 - [23] S. KAMBHAMPATI, K. VALMEEKAM, L. GUAN, M. VERMA, K. STECHLY, S. BHAMBRI, L. P. SALDYT, AND A. B. MURTHY, *LLMs can’t plan, but can help planning in LLM-modulo frameworks*, in Proceedings of the 41st International Conference on Machine Learning (ICML 2024), 2024.
 - [24] V. KARPUKHIN, B. OĞUZ, S. MIN, P. LEWIS, L. WU, S. EDUNOV, D. CHEN, AND W. TAU YIH, *Dense passage retrieval for open-domain question answering*, in Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020), 2020, pp. 6769–6781.
 - [25] J. KASAI, K. SAKAGUCHI, Y. TAKAHASHI, R. L. BRAS, A. ASAI, X. YU, D. RADEV, N. A. SMITH, Y. CHOI, AND I. URIA, *Real-time QA : Teaching a language model to answer questions based on real-time information*, in Advances in Neural Information Processing Systems 36 (NeurIPS 2023), 2023.
 - [26] J. E. LAIRD, *The Soar Cognitive Architecture*, MIT Press, Cambridge, MA, 2012.
 - [27] J. E. LAIRD, C. LEBIERE, AND P. S. ROSENBLOOM, *A standard model of the mind : Toward a common computational framework across artificial general intelligence, cognitive science, neuroscience, and robotics*, AI Magazine, 38 (2017), pp. 13–26.
 - [28] P. LEWIS, E. PEREZ, A. PIKTUS, F. PETRONI, V. KARPUKHIN, N. GOYAL, H. KÜTTLER, M. LEWIS, W. TAU YIH, T. ROCKTÄSCHEL, S. RIEDEL, AND D. KIELA, *Retrieval-augmented generation for knowledge-intensive NLP tasks*, in Advances in Neural Information Processing Systems 33 (NeurIPS 2020), 2020, pp. 9459–9474.

- [29] S. LIN, J. HILTON, AND O. EVANS, *TruthfulQA : Measuring how models mimic human falsehoods*, in Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL 2022), 2022, pp. 3214–3252.
- [30] N. F. LIU, K. LIN, J. HEWITT, A. PARANJAPE, M. BEVILACQUA, F. PETRONI, AND P. LIANG, *Lost in the middle : How language models use long contexts*, Transactions of the Association for Computational Linguistics, 12 (2024), pp. 157–173.
- [31] META AI, *Llama 3 model card*, tech. rep., Meta Platforms, Inc., 2024.
- [32] R. MFEGUE, *GOV-AI : Conception et déploiement d’une intelligence artificielle conversationnelle gouvernementale sur infrastructure souveraine*, Master’s thesis, Université de Yaoundé I, 2025.
Mémoire de master, CENADI.
- [33] N. MUENNIGHOFF, N. TAZI, L. MAGNE, AND N. REIMERS, *MTEB : Massive text embedding benchmark*, in Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics (EACL 2023), 2023, pp. 2014–2037.
- [34] R. NAKANO, J. HILTON, S. BALAJI, J. WU, L. OUYANG, C. KIM, C. HESSE, S. JAIN, V. KOSARAJU, W. SAUNDERS, X. JIANG, K. COBBE, T. ELOUNDOU, G. KRUEGER, K. BUTTON, M. KNIGHT, B. CHESS, AND J. SCHULMAN, *WebGPT : Browser-assisted question-answering with human feedback*, 2021.
arXiv preprint arXiv :2112.09332.
- [35] NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY, *Artificial intelligence risk management framework (AI RMF 1.0)*, Tech. Rep. NIST AI 100-1, NIST, Gaithersburg, MD, 2023.
- [36] ———, *Artificial intelligence risk management framework : Generative artificial intelligence profile*, Tech. Rep. NIST AI 600-1, NIST, Gaithersburg, MD, 2024.
- [37] M. NDULO, *African customary law, customs, and women’s rights*, Indiana Journal of Global Legal Studies, 18 (2011), pp. 87–120.
- [38] J. NIELSEN, *Usability Engineering*, Academic Press, Boston, MA, 1993.
- [39] OECD, *Recommendation of the council on artificial intelligence*, Tech. Rep. OECD/LEGAL/0449, Organisation for Economic Co-operation and Development, 2019.
- [40] OPENAI, *GPT-4 technical report*, tech. rep., OpenAI, 2023.
arXiv preprint arXiv :2303.08774.

- [41] ORGANISATION POUR L'HARMONISATION EN AFRIQUE DU DROIT DES AFFAIRES, *Traité relatif à l'Harmonisation du Droit des Affaires en Afrique*, 1993.
Signé à Port-Louis le 17 octobre 1993.
- [42] L. OUYANG, J. WU, X. JIANG, D. ALMEIDA, C. WAINWRIGHT, P. MISHKIN, C. ZHANG, S. AGARWAL, K. SLAMA, A. RAY, J. SCHULMAN, J. HILTON, F. KELTON, L. MILLER, M. SIMENS, A. ASKELL, P. WELINDER, P. CHRISTIANO, J. LEIKE, AND R. LOWE, *Training language models to follow instructions with human feedback*, in *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, 2022, pp. 27730–27744.
- [43] OWASP FOUNDATION, *OWASP top 10 for large language model applications*, tech. rep., Open Worldwide Application Security Project, 2025.
Version 2.0.
- [44] C. PACKER, V. FANG, S. G. PATIL, K. LIN, S. WOODERS, AND J. E. GONZALEZ, *MemGPT : Towards LLMs as operating systems*, 2023.
arXiv preprint arXiv :2310.08560.
- [45] M. PALMIRANI, G. GOVERNATORI, A. ROTOLO, S. TABET, H. BOLEY, AND A. PASCHKE, *LegalRuleML : XML-based rules and norms*, in *Rule-Based Modeling and Computing on the Semantic Web*, vol. 7018 of *Lecture Notes in Computer Science*, Springer, 2011, pp. 298–312.
- [46] S. PAN, L. LUO, Y. WANG, C. CHEN, J. WANG, AND X. WU, *Unifying large language models and knowledge graphs : A roadmap*, *IEEE Transactions on Knowledge and Data Engineering*, 36 (2024), pp. 3580–3599.
- [47] J. S. PARK, J. C. O'BRIEN, C. J. CAI, M. R. MORRIS, P. LIANG, AND M. S. BERNSTEIN, *Generative agents : Interactive simulacra of human behavior*, in *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST 2023)*, 2023, pp. 1–22.
- [48] REPUBLIC OF ESTONIA, MINISTRY OF ECONOMIC AFFAIRS AND COMMUNICATIONS, *Principles of the estonian AI policy 2019–2021*, 2019.
KrattAI Initiative.
- [49] RÉPUBLIQUE DU CAMEROUN, *Constitution de la République du Cameroun*, 1996.
Loi n° 96/06 du 18 janvier 1996 portant révision de la Constitution du 2 juin 1972.
- [50] S. E. ROBERTSON, S. WALKER, S. JONES, M. M. HANCOCK-BEAULIEU, AND M. GATFORD, *Okapi at TREC-3*, in *Proceedings of the Third Text Retrieval Conference (TREC-3)*, 1994, pp. 109–126.

- [51] T. SCHICK, J. DWIVEDI-YU, R. DESSÌ, R. RAILEANU, M. LOMELI, L. ZETTLEMOYER, N. CANCEDDA, AND T. SCIALOM, *Toolformer : Language models can teach themselves to use tools*, in Advances in Neural Information Processing Systems 36 (NeurIPS 2023), 2023.
- [52] N. SHINN, F. CASSANO, A. GOPINATH, K. NARASIMHAN, AND S. YAO, *Reflexion : Language agents with verbal reinforcement learning*, in Advances in Neural Information Processing Systems 36 (NeurIPS 2023), 2023.
- [53] N. THAKUR, N. REIMERS, A. RÜCKLÉ, A. SRIVASTAVA, AND I. GUREVYCH, *BEIR : A heterogeneous benchmark for zero-shot evaluation of information retrieval models*, in Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS 2021), 2021.
- [54] UNESCO, *Recommendation on the ethics of artificial intelligence*, tech. rep., United Nations Educational, Scientific and Cultural Organization, Paris, 2021.
- [55] UNITED NATIONS DEPARTMENT OF ECONOMIC AND SOCIAL AFFAIRS, *United nations e-government survey 2024 : Accelerating digital transformation for sustainable development*, 2024.
- [56] A. VASWANI, N. SHAZEER, N. PARMAR, J. USZKOREIT, L. JONES, A. N. GOMEZ, Ł. KAISER, AND I. POLOSUKHIN, *Attention is all you need*, in Advances in Neural Information Processing Systems 30 (NeurIPS 2017), 2017, pp. 5998–6008.
- [57] D. VERNON, G. METTA, AND G. SANDINI, *A survey of artificial cognitive systems : Implications for the autonomous development of mental capabilities in computational agents*, IEEE Transactions on Evolutionary Computation, 11 (2007), pp. 151–180.
- [58] L. WANG, C. MA, X. FENG, Z. ZHANG, H. YANG, J. ZHANG, Z.-Y. CHEN, J. TANG, X. CHEN, Y. LIN, W. X. ZHAO, Z. WEI, AND J.-R. WEN, *A survey on large language model based autonomous agents*, Frontiers of Computer Science, 18 (2024), p. 186345.
- [59] L. WANG, W. XU, Y. LAN, Z. HU, Y. LAN, R. K.-W. LEE, AND E.-P. LIM, *Plan-and-solve prompting : Improving zero-shot chain-of-thought reasoning by large language models*, in Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023), 2023, pp. 2609–2634.
- [60] J. WEI, X. WANG, D. SCHUURMANS, M. BOSMA, B. ICHTER, F. XIA, E. CHI, Q. LE, AND D. ZHOU, *Chain-of-thought prompting elicits reasoning in large language models*, in Advances in Neural Information Processing Systems 35 (NeurIPS 2022), 2022, pp. 24824–24837.

- [61] S. YAO, J. ZHAO, D. YU, N. DU, I. SHAFRAN, K. NARASIMHAN, AND Y. CAO, *ReAct : Synergizing reasoning and acting in language models*, in The Eleventh International Conference on Learning Representations (ICLR 2023), 2023.
- [62] W. ZHANG, Y. DU, S. WEI, AND B. LIU, *Impact of OCR quality on retrieval-augmented generation performance*, in Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing Workshops, 2024.
- [63] Z. ZHANG, X. BO, C. MA, R. LI, X. CHEN, Q. DAI, J. ZHU, Z. DONG, AND J.-R. WEN, *A survey on the memory mechanism of large language model based agents*, 2024. arXiv preprint arXiv :2404.13501.
- [64] S. ZHOU, F. F. XU, H. ZHU, X. ZHOU, R. LO, A. SRIDHAR, X. CHENG, Y. BISK, D. FRIED, U. ALON, AND G. NEUBIG, *WebArena : A realistic web environment for building autonomous agents*, in The Twelfth International Conference on Learning Representations (ICLR 2024), 2024.

